




**INSTITUTO FEDERAL
DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA**
São Paulo




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

COLETÂNEA DE POSTS EAILAB

2023-2026



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Volume 1

2026

Sumário

Prefácio.....	3
Post 1: 10 Tendências de Aplicação de Inteligência Artificial em 2024!.....	4
Post 2: Tendências em Edge Computing.....	7
Post 3: PAL ET: A Solução para os Desafios de AIoT em Edge Computing.....	12
Post 4: Função de Ativação, o Núcleo da Composição de Neurônios Artificiais.....	20
Post 5: Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML.....	32
Post 6: Datasets de Acesso Livre para Projetos de IA!.....	44
Post 7: Excelentes Recursos para Estudar Aprendizado de Máquina.....	47
Post 8: Principais Algoritmos Utilizados em Inteligência Artificial.....	49
Post 9: O Poder Das CNNs Em Aplicações de ML Envolvendo Identificação e Classificação de Imagens.....	61
Post 10: Roteiro Para Criação de Dataset de Imagens Para modelos de Aprendizagem Profunda.....	67
Post 11: Melhores bibliotecas Python para aprendizado de máquina.....	76
Post 12: Métricas de Desempenho em Modelos de IA (parte 1).....	83
Post 13: Métricas de Desempenho em Modelos de IA (parte 2).....	96
Post 14: Evolução da IA Tradicional para a IA Generativa e Agencial.....	105
Post 15: Transformers: A Arquitetura Que Revolucionou a IA Contemporânea.....	123
Post 16: Probabilidade Aplicada à IA.....	131
ANEXO 1 - Pipeline de Classificação de Imagens com Inteligência Artificial.....	138



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Prefácio

Este documento reúne uma coletânea dos *posts* sobre a inteligência artificial (IA), aprendizado de máquina (*machine learning* – ML), Tiny ML e computação na borda (*edge computing*) publicados na página do EAILab no período entre 2023 e 2026.

O objetivo deste documento é servir como uma referência preliminar sobre assuntos relacionados à IA, em especial à IA embarcada, diferentes estratégias de aplicação, tendências e evolução.

Dr. Arnaldo de Carvalho Junior


EAILAB – IFSP

<https://eailab.labmax.org/>

Volume 1

Edição 2 - Ampliada e Revisada

Setembro 2026



EAILab


Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Post 1: 10 Tendências de Aplicação de Inteligência Artificial em 2024!


Há um século, a economia dependia fortemente de trabalho manual. Com o acelerado desenvolvimento da eletrônica e informática, principalmente após a segunda guerra mundial, várias tecnologias capazes de realizar cálculos complexos foram introduzidas. Assim, em poucas décadas a humanidade saiu dos processos manuais de cálculo como ábaco para os mais recentes computadores quânticos. Essas tecnologias encontraram ampla aplicação em uma variedade de indústrias, incluindo pesquisa e desenvolvimento, defesa, medicina, processos industriais, entre outros.

Já em 1956, a inteligência artificial (IA) ficou em evidência, através do artigo “*Computing Machinery and Intelligence*” publicado pelo matemático inglês Alan Turing. Entretanto, os avanços recentes de hardware e software permitiram que a inteligência artificial ganhasse meios e massa crítica para se estabelecer como ciência integral, multidisciplinar, com aplicações nas mais diversas áreas do conhecimento humano.

A seguir são relacionadas 10 tecnologias com IA em destaque em 2024:



- a) **Plataforma de Aprendizado de Máquina (*Machine Learning* – ML):** tem o objetivo de desenvolver novos métodos para que os computadores aprendam e se tornem mais inteligentes. Algoritmos, interfaces de programação de aplicação (*Application Programming Interfaces* – APIs), desenvolvimento, ferramentas de treinamento, dados massivos e aplicações estão impulsionando o uso de ML em classificação e previsão.
- b) **Plataformas de aprendizagem profunda (*Deep Learning* – DL):** tipo de ML que analisa dados e descobre tendências usando circuitos neurais semelhantes aos encontrados no




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

cérebro humano. Exemplos de aplicações são reconhecimento de tela automatizado, reconhecimento de imagem e previsão de qualquer coisa detectável no domínio digital.

- c) **Reconhecimento de Fala (*Speech Recognition*):** método de converter a fala humana de modo que o software do computador possa entender. Traduzir e transformar a linguagem humana em formatos úteis está se expandindo rapidamente, inclusive para ações inclusivas. Diversas Corporações fornecem serviços de reconhecimento de fala.
- d) **Geração de linguagem natural:** ramo da tecnologia IA que converte o texto em dados e auxilia os sintomas a transmitir perfeitamente suas idéias e pensamentos, facilitando a comunicação entre humanos de diferentes culturas e na interação com as máquinas. Destaque para os Modelos de Linguagem de Grande Escala (*Large Language Models* – LLMs), que são modelos de ML utilizando DL para processar e entender a linguagem natural. Os LLMs são treinados em grandes volumes de dados da internet, aprendendo padrões sobre como as palavras e frases são normalmente usadas em conjunto. Quando carregado com uma nova entrada de texto, um LLM tentará gerar a continuação mais provável desse texto com base no que aprendeu durante o treinamento. Exemplo de LLM com destaque na mídia é o ChatGPT.
- e) **Agentes Virtuais:** softwares que permitem a máquina se comunicar e interagir efetivamente com os humanos. A IA está sendo cada vez mais empregada no suporte ao cliente por meio de Chatbots e como um gerenciador de casa inteligente.
- f) **Gerenciamento de Decisão (*Decision Management*):** Pode-se incorporar IA em robôs preparando-os para treinamento, gerenciamento e ajuste. As organizações já estão incorporando o gerenciamento de decisões em seus aplicativos para planejar e executar decisões automáticas que agregam valor ao negócio e aumentam sua viabilidade. Além disso, as técnicas de IA e ML, treinadas e validadas por um especialista humano, podem ser utilizadas em sistemas especialistas para tomada de decisão (*decision making expert systems*) com aplicações em diagnóstico médico, controle automatizado de sistemas, veículos autônomos, entre outras finalidades.
- g) **Automação Robótica de Processos:** Automação é a execução de tarefas por técnicas computadorizadas ou mecânicas que outrora era executada por humanos. Ela destina-se a aumentar e complementar as habilidades humanas, bem como executar tarefas repetitivas ou que envolvam algum grau de risco.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- h) **Biométrica:** a ciência de reconhecer, medir e analisar as características físicas do corpo humano. Ela permite criar interações orgânicas entre humanos e máquinas, utilizando coisas, imagens, palavras e linguagem corporal. É usado principalmente para pesquisas de mercado.
- i) **Hardware otimizado para IA:** dispositivos estão sendo projetados e construídos com processamento e gráficos otimizados para executar tarefas relacionadas à IA. Organizações estão investindo pesadamente em IA para acelerar o desenvolvimento da próxima geração de serviços, como Google, Intel, e Nvidia.
- j) **Defesa Cibernética:** mecanismo de defesa do computador que detecta, previne e mitiga ataques e ameaças contra o sistema e a infraestrutura de dados. Pode-se combinar redes neurais artificiais (*Artificial Neural Networks* – ANNs) com técnicas de aprendizagem de máquina para descobrir a atividade suspeita do usuário e detectar riscos de segurança cibernética.


REFERÊNCIA

N. Duggal. Top 10 Artificial Intelligence Technologies in 2024, SimpliLearn. Published in Nov, 24, 2023. Disponível em: <https://www.simplilearn.com/top-artificial-intelligence-technologies-article>. Acessado em 28 de novembro de 2023.

Elaborado Por: Dr. Arnaldo de Carvalho Junior.

Publicado em: Nov 28, 2023.

Disponível em: <https://eailab.labmax.org/2023/11/28/10-tendencias-de-aplicacao-de-inteligencia-artificial-em-2024/>. Acessado em Nov 08, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Post 2: Tendências em Edge Computing

A internet das coisas (*internet of things* – IoT) refere-se a um massivo conjunto de dispositivos conectados em rede. A internet facilita a comunicação entre os próprios dispositivos, sistemas de gerenciamento e a nuvem (cloud).

O termo IoT surgiu em 1985 [1], antes mesmo de a internet se tornar popular. O termo refere-se à integração entre pessoas, processos e tecnologias via dispositivos conectáveis e acessíveis por qualquer tecnologia.

Entre as principais aplicações de IoT pode-se destacar a Indústria 4.0 ou internet das coisas industriais (*industrial internet of things* – IIoT), logística 4.0, agricultura 4.0, telemedicina, transporte 4.0, etc. [2].



Figura 1 – Aplicações de Smart IoT (adaptado de [2]).

A integração da inteligência artificial (artificial Intelligence – AI), aprendizado de máquina (*machine learning* – ML) e aprendizado profundo (deep learning) ao sistema IoT amplia o leque de possibilidades, aumentando a automatização e o poder de decisão dos sistemas IoT, tornando-os inteligentes (*smart*). A inteligência artificial das coisas (*artificial Intelligence of things* – AIoT) expande as capacidades analíticas e preditivas, amplificando muito o valor dos dados coletados [3].



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo




Figura 2 – AIoT.

A quantidade crescente de dispositivos conectados, a velocidade de conexão, a capacidade de processamento dos sistemas na nuvem e a latência podem afetar a performance do sistema IoT ao ponto de ser eficaz em momentos críticos de tomada de decisão. Para esses casos, surge a computação de borda (*edge computing*), onde o processamento ocorre o mais próximo possível da fonte de dados [4]. É o caso, por exemplo, dos veículos conectados e autônomos.



Figura 3 – Edge Computing em Veículos Autônomos (Adaptado de [5]).

A seguir são apresentadas as principais tendências em **Edge Computing** [7,8]:



- k) **Computação em tempo real (*real-time computing*):** a necessidade de respostas imediatas, sem esperar pelo processamento em nuvem, está forçando o desenvolvimento acelerado de soluções de edge computing.
- l) **Inteligência Artificial na Borda (*edge artificial Intelligence – EAI*):** Soluções de edge computing, incluindo técnicas de AI e ML em dispositivos compactos (*tiny ML*), capazes de realizar análises complexas para a tomada de decisões, aumentam a eficiência e reduzem a necessidade de enviar grandes quantidades de dados para a nuvem.
- m) **Segurança na borda (*edge security*):** garante a integridade e confidencialidade dos dados, reduzindo a exposição e possíveis ameaças durante a transferência para a nuvem. Assim, soluções de criptografia ponta-a-ponta, autenticação de dispositivos e monitoramento em tempo real são críticos para o edge computing.
- n) **Orquestração da borda para a nuvem (*edge-to-cloud orchestration*):** tomar a transição de dados entre a borda e a nuvem tão suave quanto possível proporcionará uma experiência de usuário mais consistente. Isso é possível com a orquestração eficiente entre a borda e a nuvem, garantindo a coesão nos ecossistemas de computação distribuída e a otimização do fluxo de dados através de ferramentas avançadas de gerenciamento do sistema.
- o) **Conectividade borda-a-borda (*edge-to-edge connectivity*):** fundamental para uma colaboração eficiente entre dispositivos, em aplicações que exigem ação coordenada em tempo real.
- p) **Integração com 5G:** tecnologia de redes de comunicação móvel 5G garante não só maior velocidade de transmissão de dados, mas também redução significativa da latência. A expansão de redes 5G, tanto públicas quanto privadas, facilitará a rápida transferência de dados entre dispositivos e pontos de processamento próximos.
- q) **Convergência entre tecnologia da informação e tecnologia da operação (*information technology (IT) – operational technology (OT) convergence*):** A convergência IT/OT melhora a integração e a colaboração de domínios tradicionalmente separados, permitindo a comunicação consistente e troca de dados entre dispositivos de borda e sistemas backend. Além disso, os sistemas integrados de IT/OT podem erradicar operações desarticuladas e isoladas, estabelecendo coordenação e fluxos de informação eficientes. A convergência IT/OT ainda auxilia no gerenciamento e controle unificados da infraestrutura de IT e OT, levando a uma maior eficiência operacional e otimização de recursos. Análises avançadas, monitoramento em



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

tempo real e manutenção preditiva na borda, melhorando a confiabilidade e o desempenho dos sistemas de computação na borda, são possíveis. A fusão IT/OT promove, assim, protocolos padronizados e interoperabilidade entre dispositivos.

- r) **Sustentabilidade na borda (*sustainability at the edge*)**: o edge computing pode auxiliar no desenvolvimento de dispositivos e sistemas que otimizem o consumo de energia e minimizem a pegada de carbono, promovendo equilíbrio entre inovação e responsabilidade social.




Figura 4 – Edge Computing (Adaptado de [8]).

Com a evolução da tecnologia edge computing haverá uma migração massiva da nuvem para a borda [6]. Processadores pequenos e poderosos, ferramentas matemáticas robustas e algoritmos eficazes usando poucos recursos computacionais serão essenciais em aplicações de *edge computing*.

REFERÊNCIAS

- [1] Sharma, C. Correcting the IoT history. 14 mar 2016. Disponível em: <https://www.chetansharma.com/correcting-the-iot-history/>. Acessado em 12 dez 2023.
- [2] Whaiduzzaman, M.; Barros, A.; Chanda, M.; Barman, S.; Sultana, T.; Rahman, M.S.; Roy, S.; Fidge, C. A Review of Emerging Technologies for IoT-Based Smart Cities. *Sensors* 2022, 22, 9271. <https://doi.org/10.3390/s22239271>.
- [3] Kamal, R. Use Cases And Advantages Of AIoT: Merging AI And IoT technologies. 2022. Disponível em: <https://www.intuz.com/blog/use-cases-and-advantages-of-aiot..> Acessado em Dez 12, 2023.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[4] CBInsights. What is Edge Computing? 11 mar 2021. Disponível em: <https://www.cbinsights.com/research/what-is-edge-computing/>. Acessado em Dez 12, 2023.

[5] Lu, S.; Shi, W. Vehicle Computing: Vision and challenges, Journal of Information and Intelligence, Vol. 1, Issue 1, 2023, pp. 23-35, ISSN 2949-7159, <https://doi.org/10.1016/j.jiixd.2022.10.001>. Acessado em Dez 12, 2023.


[7] StartUs Insights. Explore the Top 10 Edge Computing Trends in 2024. Disponível em: <https://www.startus-insights.com/innovators-guide/edge-computing-trends/>. Acessado em Dez 12, 2023.

[8] Kasam, A. Top Five Edge Computing Trends to Watch Out for in 2024. 16 out 2023. Disponível em: <https://enterprisetalk.com/featured/top-five-edge-computing-trends-to-watch-out-for-in-2024/>. Acessado em Dez 12, 2023.

Elaborado Por: Dr. Arnaldo de Carvalho Junior

Publicado em: Dez 12, 2023

Disponível em: <https://eailab.labmax.org/2023/12/12/tendencias-em-edge-computing/>. Acessado em Nov 08, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Post 3: PAL Et: A Solução para os Desafios de AIoT em Edge Computing

1. INTRODUÇÃO

A inteligência artificial - IA (*artificial intelligence* – AI) tem se desenvolvido de forma acelerada nos últimos anos, com aplicações nas mais diversas áreas do conhecimento humano. Aprendizado de máquina (*machine learning* – ML), reconhecimento de fala, geração de linguagem natural, aprendizagem profunda (*deep learning* – DL), biometria, diagnósticos, cibersegurança, automação e robótica estão entre as principais tendências de desenvolvimento futuros em AI [1].


Outra frente de destaque de desenvolvimento tecnológico deste século é a internet das coisas (*internet of things* – IoT) e seus mais diversos campos de interesse, como indústrias, automação de cidades, agronegócio, logística, infraestrutura, entre outros [2].

A adição da AI ao IoT eleva este último a um novo patamar, aumentando a eficiência das operações de tecnologia da informação (*information technology* – IT), as interações entre homem e máquina, melhor gerenciamento e análise dos dados. A AI + IoT cria um novo paradigma tecnológico, chamado de inteligência artificial das coisas (*artificial intelligence of things* – AIoT) [2].

A arquitetura da IoT pressupõe uma massiva quantidade e diversidade de sensores, conectividade via rede de telecomunicações, gerando um grande volume de dados (big data) que é direcionado para processamento em nuvem ou em camada intermediária da arquitetura (*fog*) [2].

No entanto, há situações em que a análise, diagnóstico e tomada de decisão devem ser realizadas de forma ágil e rápida, sem atrasos. Nesses casos, o processamento ocorrendo o mais próximo da fonte de dados (sensores), o chamado processamento de borda (*edge computing*), é importante [2]. Infelizmente, os dispositivos de edge computing e sistemas embarcados (*embedded systems*) podem ter recursos computacionais limitados. A implementação de algoritmos de AI, ML, e sistemas para tomada de decisões que apresentem baixa complexidade e consumam poucos recursos são desejáveis. Neste cenário, uma tecnologia que se destaca é a lógica paraconsistente anotada evidencial (*paraconsistent annotated evidential logic* – PAL Et) [3].

A PAL Et pertence à família de lógicas paraconsistentes, podendo lidar com informações inconsistentes e contraditórias, sem que o peso dos conflitos invalide as conclusões. A PAL Et possui algoritmo robusto, matemática de baixa complexidade, reversibilidade, poucas regras e decisões. Por estas características ela vem ganhando atração entre pesquisadores das mais diversas áreas, de automação e robótica a sistemas de diagnóstico médico e tomada de decisão [3].



2. UM POUCO SOBRE PAL ET

A PAL ET utiliza 1 ou mais variáveis, geralmente um par (μ_1, μ_2) , como anotações ou evidências em um diagrama de Lattice de 4 vértices, expressam o conhecimento sobre uma determinada proposição **P**. O poder de representar evidências e analisar contradições no diagrama de Lattice da PAL ET ficou demonstrado em uma ampla gama de pesquisas, desde partir do cálculo diferencial integral paraconsistente, ao modelo de Bohr para níveis de energia do Hidrogênio átomo, energia escura e teoria da relatividade, e até uma derivação para a lógica paraquântica [3].

Uma das variáveis suporta a proposição **P**, sendo chamada de grau de evidência favorável ($\mu = \mu_1$). A outra variável será contrária à proposição **P**, sendo denominada de grau de evidência desfavorável (λ). Se ambas as variáveis suportam a proposição **P**, utiliza-se o complemento de uma delas como desfavorável ($\lambda = 1 - \mu_2$). A Figura 1 a seguir apresenta o diagrama de Lattice da PAL ET. Uma boa descrição do algoritmo básico (Figura 2) pode ser encontrada na referência [4].




Figura 1 – Diagrama de Lattice da PAL Et [3]



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Figura 2 – Algoritmo básico da PAL Et [4]

3. APLICAÇÕES DA PAL Et EM AIOT E EDGE COMPUTING

A grande vantagem da PAL Et está no uso de regras e operações matemáticas simples, o que permite criar sistemas robustos e confiáveis, mesmo em dispositivos com limitações de recursos computacionais, sendo ideal para aplicações embarcadas e de *Edge Computing*.

3.1 PAL Et ou Fuzzy?



Os computadores têm dificuldade em imitar o raciocínio humano para tomada de decisão quando o valor está entre verdadeiro e falso. Em tal situação, várias técnicas têm sido exploradas, como a lógica difusa (Fuzzy logic) [3].

Apesar de amplamente utilizada, a lógica Fuzzy tem algumas limitações, pois pode exigir vários parâmetros, dezenas ou centenas de regras do tipo if-then, funções de associação e inferências. Além disso, o desenho de regras Fuzzy depende do conhecimento e da experiência humana. Se alta velocidade e extensas regras Fuzzy forem requeridas, pode não ser viável utilizá-la em um sistema especialista embarcado, com recursos computacionais limitados. A PAL ET, por outro lado, pode fornecer velocidade computacional em sistemas especialistas. Simples equações são extraídas das análises no diagrama de Lattice da PAL ET, facilitando o desenvolvimento de sistemas especializados com incertezas [3].





Figura 3 – Divisão do Lattice PAL ET em 12 estados lógicos e o diagrama de blocos do algoritmo Para-Analyzer, concorrente direto da lógica Fuzzy [3].



O diagrama de Lattice da PAL ET pode ser dividido em um certo número de regiões, ou “estados lógicos”, usados para tomada de decisões. Um exemplo típico é a divisão em 12 regiões, utilizadas, por exemplo, para a toma de decisão de direção de um robô móvel, como proposto em [5]. Um exemplo de demonstração do algoritmo da PAL ET em Matlab, e sua saída tanto na forma de resposta a uma proposição P, como em um de 12 estados lógicos paraconsistentes pode ser observado em [6].

3.2. PAL ET ou Kalman?


Em muitas situações os sensores utilizados em IoT ou em sistemas embarcados são contaminadas por ruídos e imprecisões. O filtro Kalman é um algoritmo bastante utilizado e que produz estimativas dos valores reais de grandezas medidas e valores associados predizendo um valor, estimando a incerteza do valor predito e calculando uma média ponderada entre o valor predito e o valor medido. Entre as vantagens do Filtro Kalman está o fato de ser baseado em sistemas dinâmicos lineares discretizados no domínio do tempo e operar com matrizes, permitindo a construção de sistemas de múltiplas entradas e múltiplas saídas (*multiple input multiple output* – MIMO). Entretanto, há situações em que um simples filtro-passa-baixas de primeira ou segunda ordem é suficiente para estimar o valor de uma variável. Para esses casos a PAL ET pode ser uma solução [7,8]. Conforme a Figura 4, a saída atual ($\mu_E[n]$) do PAL2v Filter (outro nome para PAL ET) consiste basicamente de uma parcela (1-FL) da saída anterior ($\mu_E[n-1]$) mais uma parcela (F_L) da entrada atual ($\mu[n]$), conforme a equação apresentada na Figura 4, onde F_L corresponder ao fator de aprendizagem e é o ajuste do filtro. Pode-se cascatear várias unidades do PAL2v Filter para criar filtros de ordem superior, como demonstrado na referência [9] disponibilizada em Matlab.

$$\mu_E[n] = (1 - F_L) * \mu_E[n - 1] + F_L * \mu[n]$$

Figura 4 – Equação básica do Filtro PAL2v de Primeira ordem [7].

3.3. Redes Neurais Artificiais com PAL ET?

O algoritmo básico da PAL ET pode ser utilizado para compor a função de ativação de um neurônio. A interligação de vários neurônios PAL ET podem ser usadas para formar uma rede neural paraconsistente (*paraconsistent neural network* – PNN). Foi demonstrado em [10] que uma PNN



apresentou vantagens em relação a redes neurais artificiais (*artificial neural network* – ANN) com funções de ativação clássicas (sigmoide, tanh e ReLU) para a identificação de um sistema dinâmico não linear de pêndulo invertido [10]. Da mesma forma, um sistema de controle por modelo de referência (*model reference control* – MRC), composto por 3 redes neurais paraconsistentes recorrentes (*recurrent paraconsistent neural network* – RPNN) foi implementado com sucesso no controle de um pêndulo invertido rotativo (*rotary inverted pendulum* – RIP), com menor esforço de energia e maior robustez que o sistema clássico de controle por alocação de polos [11]. Esse sistema utilizou apenas 14 neurônios PAL Et sendo executado em um microcontrolador ESP32 no controle em tempo real do RIP, demonstrando o potencial de utilização de redes neurais paraconsistentes em sistemas embarcados e de *edge computing*.

A Figura 5 apresenta um exemplo de PNN. Uma comparação entre PNN e ANN na forma de algoritmo de Matlab está disponível na referência [12].





Figura 5 – Paraconsistent Neural Network (PNN)

4. CONSIDERAÇÕES FINAIS

Esse post apresentou alguns algoritmos e suas aplicações bem-sucedidas da PAL Et na tomada de decisões, filtragem e tratamento de sinal, classificação, reconhecimento de padrões, identificação e



EAILab


Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

controle. A simplicidade das equações e regras da PAL Et são características importantes e que devem ser levadas em consideração em projetos de sistemas AIoT embarcados e de computação de borda.

Para saber mais sobre a PAL Et, um bom começo pode ser a página “PAL2v: Key Points”, que complementa as referências listadas neste post e está disponível em [13]. Nela há referência aos principais algoritmos, os links para exemplos em Matlab e um conjunto de artigos de referência de alto fator de impacto sobre a lógica.

REFERÊNCIAS

- [1] De Carvalho Junior, A. 10 Tendências de Aplicação de Inteligência Artificial em 2024! EAILAB, publicado em nov 28, 2023. Disponível em: <https://eailab.labmax.org/2023/11/28/10-tendencias-de-aplicacao-de-inteligencia-artificial-em-2024/>
- [2] De Carvalho Junior, A. Tendências em Edge Computing. EAILAB, publicado em dez 12, 2023. Disponível em: <https://eailab.labmax.org/2023/12/12/tendencias-em-edge-computing/>
- [3] De Carvalho Junior, A.; Justo, J. F.; De Oliveira, A. M.; Da Silva Filho, J. I., A comprehensive review on paraconsistent annotated evidential logic: Algorithms, Applications, and Perspectives, Engineering Applications of Artificial Intelligence, Volume 127, Part B, 2024, 107342, ISSN 0952-1976 DOI: 10.1016/j.engappai.2023.107342.
- [4] Da Silva Filho, J. I. Treatment of Uncertainties with Algorithms of the Paraconsistent Annotated Logic, Journal of Intelligent Learning Systems and Applications, Vol. 4 No. 2, 2012, pp. 144-153. DOI: 10.4236/jilsa.2012.42014. Disponível em: <https://www.scirp.org/journal/paperinformation.aspx?paperid=19263>. Acessado em dez 21, 2023.
- [5] Abe, J.M., Torres, C.R., Lambert-Torres, G., Nakamatsu, K., Kondo, M., 2006b. Intelligent paraconsistent logic controller and autonomous mobile robot emmy II. In: Lecture Notes in Computer Science. Springer, Berlin, Heidelberg, pp. 851–857. http://dx.doi.org/10.1007/11893004_108.
- [6] De Carvalho Junior, A. (2023). PAL2v Para-Analyzer, MATLAB Central File Exchange. Retrieved November 22, 2023. Disponível em: <https://www.mathworks.com/matlabcentral/fileexchange/155422-pal2v-para-analyzer>. Acessado em dez 21, 2023.
- [7] De Carvalho Jr., A. et al. (2023). A Paraconsistent Artificial Neural Cell of Learning by Contradiction Extraction (PANCLCTX) with Application Examples. In: Abe, J.M. (eds) Advances in Applied Logics. Intelligent Systems Reference Library, vol 243. Springer, Cham. DOI: 10.1007/978-3-031-35759-6_5.



EAILab


Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- [8] Carvalho, A., Justo, J.F., Angélico, B.A. et al. Paraconsistent State Estimator for a Furuta Pendulum Control. SN COMPUT. SCI. 4, 29 (2023). <https://doi.org/10.1007/s42979-022-01427-z>
- [9] De Carvalho Junior, A. (2023). PAL2v Filter, MATLAB Central File Exchange. Retrieved May 24, 2023. Disponível em: <https://www.mathworks.com/matlabcentral/fileexchange/129644-pal2v-filter>. Acessado em dez 21, 2023.
- [10] Carvalho, A., Justo, J. F., Angélico, B. A. et al, "Rotary Inverted Pendulum Identification for Control by Paraconsistent Neural Network," in IEEE Access, doi: 10.1109/ACCESS.2021.3080176.
- [11] Carvalho, A., Justo, J.F., Angélico, B.A. et al. Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946, DOI: 10.1016/j.asoc.2022.109927.
- [12] De Carvalho Junior, A. Paraconsistent Neural Network (PNN), MathWorks, Retrieved June 13, 2023. Disponível em: <https://www.mathworks.com/matlabcentral/fileexchange/130739-paraconsistent-neural-network-pnn>. Acessado em Dez 21, 2023.
- [13] De Carvalho Junior, A. PAL2v: Key Points, Google Sites, 2024. Disponível em <https://sites.google.com/view/prof-amaldo/pal2v-key-points>. Acessado em Jan 09, 2024.

Elaborado Por: Dr. Arnaldo de Carvalho Junior

Publicado em: Jan 09, 2024

Disponível em: <https://eailab.labmax.org/2024/01/09/pal-e%cf%84-a-solucao-para-os-desafios-de-aiot-em-edge-computing/>. Acessado em Nov 08, 2024.

**Post 4: Função de Ativação, o Núcleo da Composição de Neurônios Artificiais****1. INTRODUÇÃO**

As redes neurais artificiais – RNAs (*artificial neural networks* – ANN) são algoritmos poderosos, muito utilizados em aplicações de inteligência artificial (IA) e aprendizado de máquina (*machine learning* – ML). As RNAs são capazes de “aprender” uma determinada função ou reconhecimento de padrões, despertando interesse em diversas áreas do conhecimento humano, de medicina diagnóstica a robótica, automação e controle de sistemas complexos [1].

As RNAs são constituídas de neurônios artificiais cujas funções matemáticas são inspiradas em neurônios biológicos, constituindo a base de redes neurais artificiais. A Figura 1 apresenta um exemplo de interligação de neurônios para compor uma RNA.





Figura 1 – Exemplo de RNA composta por neurônios artificiais interligados

Fonte: Adaptado de [2]

Apesar de não ter a mesma complexidade de um cérebro, as RNAs apresentam duas similaridades básicas com as redes neurais biológicas [3]:

1. Possibilidade de descrição de seus blocos de construção por dispositivos computacionais simples;
2. As conexões entre os neurônios determinam a função da rede.

A Figura 2 apresenta uma representação de um neurônio biológico. Já a Figura 3 apresenta um neurônio artificial de múltiplas entradas.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo




Figura 2 – Representação de um neurônio biológico.

Fonte: Adaptado de [1]





Figura 3 – Representação de neurônio artificial de múltiplas entradas.

Fonte: Adaptado de [1]

No neurônio biológico, os dendritos são filamentos responsáveis por receber os sinais de informações para as células. O corpo celular, ou soma, reúne as informações recebidas pelos dendritos. Já o axônio transporta os impulsos elétricos que partem do corpo celular até as diversas ramificações com dilatações bulbosas conhecidas como terminais axônicos (ou terminais nervosos), que estabelecem as conexões sinápticas com outras células [1].

Conforme a Figura 3, o neurônio artificial consiste de 2 etapas. A primeira é a somatória ponderada dos sinais de entrada, que em seguida são aplicados a uma função de ativação. Os pesos (w) representam a força das sinapses e são multiplicados aos valores das respectivas entradas e somados, com um



valor de ajuste ou bias (b). O resultado desta soma (n) é então aplicado a uma função de ativação (f) e apresentado na saída (a) do neurônio artificial. Um neurônio artificial pode ser descrito como:

$$n = w_{1,1}p_1 + w_{1,2}p_2 + w_{1,3}p_3 + \dots + w_{1,R}p_R$$

$$a = f(Wp + b)$$

As funções de ativação são um elemento fundamental das RNAs. Elas essencialmente decidem se um neurônio deve ser ativado ou não. Em outras palavras, se o que o neurônio está recebendo é relevante para a informação fornecida ou deve ser desprezada [4].

Várias funções f podem ser utilizadas, mas é importante que a função de ativação adotada seja derivável, de modo a permitir a elaboração de algoritmos de regressão para calibração, ou “aprendizado”, dos pesos e bias do neurônio [3]. Pode ser demonstrado que se a função de ativação for não linear, uma RNA de duas camadas pode ser um aproximador universal de função [5].

2. FUNÇÕES DE ATIVAÇÃO

As Figuras 4 e 5 apresentam algumas das funções de ativação mais utilizadas em projetos de RNAs [6].





Figura 4 – Funções de Ativação Clássicas



Fonte: Adaptado de [6]




Figura 5 – Funções de Ativação baseadas em Retificadores

Fonte: Adaptado de [6]

2.1. Função Step

A função de ativação mais elementar é a Função Degrau (Step), onde o classificador é baseado em um limiar de ativação (*threshold*). Ela foi utilizada nos primeiros neurônios artificiais foi introduzido em 1943 por W. McCulloch e W. Pitts [3].

$$f(n) = 1, n \geq 0$$


$$f(n) = 0, n < 0$$

$$f'(n) = 0$$

A função Step é mais teórica do que prática, pois em geral há mais de uma classe de dados para serem classificados. Além disso, o gradiente da função Step é zero, dificultando processos de aprendizagem da RNA.

2.2. Função Linear ou Identidade

A função identidade também é uma função simples, cuja derivada resulta em uma constante (α), não importa o valor da entrada x . Isso dificulta os processos de aprendizagem da RNA. Todavia a função linear pode ser ideal para tarefas simples, onde a interpretabilidade é altamente desejada [4], como por exemplo o neurônio da camada de saída da RNA.



$$f(n) = \alpha n$$

$$f'(n) = \alpha$$

2.3. Função Sigmoides

Uma das funções de ativação mais utilizadas nas RNAs é a log-sigmoides, por ser não linear e pela facilidade de implementação de sua derivada no processo ajuste dos pesos, conforme as equações a seguir [1],[6].


$$f(n) = \sigma(n) = \frac{1}{1 + e^{-n}}$$
$$f'(n) = \sigma(n)(1 - \sigma(n))$$

A função varia de 0 a 1 tendo um formato S. A função sigmoides essencialmente tenta empurrar os valores de Y para os extremos. Esta é uma qualidade muito desejável quando se deseja classificar os valores para uma classe específica. A função sigmoides é amplamente utilizada. Entretanto, quando os gradientes se tornam muito pequenos, a função se aproxima de zero, dificultando o aprendizado do neurônio. Sua derivada tende a 0 para valores de entrada maiores que +5 e abaixo de -5. Pelos valores de saída estarem limitados a (0,1), pode exigir algum tipo de normalização dos sinais de entrada para que sejam sempre positivos. Além disso, em geral, uma RNA composta por sigmoides utiliza mais ciclos de aprendizado do que RNAs com funções de ativação mais “rápidas” [1],[4].

2.4. Função Tangente Hiperbólica (*tanh*)

A *tanh* é outra função do tipo sigmoides. Na verdade, é apenas uma versão escalonada da função sigmoides., variando entre -1 e +1, cuja expressão e derivada são dadas pelas equações a seguir:

$$f(n) = a = \tanh(n) = \frac{e^n - e^{-n}}{e^n + e^{-n}}$$
$$f'(n) = \tanh'(n) = 1 - \tanh^2(n)$$



A *tanh* funciona de forma semelhante à função sigmoide, mas é simétrica em relação à origem, variando entre (-1,1). Ela Basicamente, soluciona o problema dos valores, sendo todos do mesmo sinal. Todas as outras propriedades são as mesmas da função sigmoide. É contínua e diferenciável em todos os pontos. A função não é linear, resultando em algoritmos de treinamento ligeiramente mais rápidos que a log-sigmoide [1],[4].


2.5. Funções Baseadas em Retificadores

A função ReLU é a unidade linear retificada (*retified linear unit* – ReLU). A função ReLU é muito parecida com a função identidade, fazendo com o processo de aprendizagem da RNA, baseado nessa função de ativação, seja muito mais rápido que por sigmóides [7].

$$a = \text{ReLU}(n) = \begin{cases} 0 & n \leq 0 \\ n & n > 0 \end{cases}$$
$$f'(n) = \text{ReLU}'(n) = \begin{cases} 0 & n \leq 0 \\ 1 & n > 0 \end{cases}$$

A ReLU é uma das funções de ativação mais utilizadas atualmente. A principal vantagem de usar a função ReLU é que ela não ativa todos os neurônios ao mesmo tempo. Na função ReLU, se a entrada for negativa, ela será convertida em zero e o neurônio não será ativado. Isso significa que, ao mesmo tempo, apenas alguns neurônios são ativados, tomando a rede esparsa, eficiente e de computação fácil. Essa vantagem também pode ser considerada uma desvantagem, pois os neurônios utilizando ReLU tendem a “morrer” durante o treinamento, causando a saída do neurônio iniciar a produzir apenas zeros. Uma variação da ReLU, chamada Leaky-ReLU (LReLU) evita isso [7] cuja função e sua derivada são apresentadas pelas equações a seguir:

$$a = \text{LReLU}(n) = \begin{cases} \alpha n & n \leq 0 \\ n & n > 0 \end{cases}$$
$$\text{LReLU}'(n) = \begin{cases} \alpha & n \leq 0 \\ 1 & n > 0 \end{cases}$$



Onde α é um parâmetro introduzido na LReLU, com valores propostos entre 0.01 e 0.2 [7]. A LReLU permite o neurônio ter um pequeno gradiente quando ele não está ativo ($n < 0$), reduzindo o problema potencial mencionado sobre ReLU [6].

2.6. Neurônio PAL2v

O neurônio PAL2v utiliza o algoritmo da lógica paraconsistente anotada com anotação de 2 valores (*paraconsistent annotated logic by 2-value annotations* – PAL2v), também chamada de lógica paraconsistente anotada evidencial (*paraconsistent annotated evidential logic* – PAL $\epsilon\tau$) [1]. A PAL2v é uma variação da lógica paraconsistente, proposta pelo matemático brasileiro Newton da Costa [1].

O neurônio PAL2v, quando entradas ponderadas por peso são combinadas e aplicadas à função de ativação PAL2v foi proposto em [1] e aplicado com sucesso na identificação e controle de sistemas dinâmicos não lineares [8],[9]. Ao contrário das funções de ativação que possuem uma entrada (n) e uma saída (a), o neurônio PAL2v possui 2 entradas ortogonais entre si (μ, λ). Esta característica dá uma flexibilidade muito grande ao neurônio PAL2v. Os sinais de interesse podem ser aplicados apenas a uma entrada enquanto que a outra funciona como um “*bias*” na função de ativação. Ou uma das entradas pode receber os sinais de interesse com pesos enquanto que a outra entrada funciona como realimentação da saída, para análise de séries temporais, como em redes neurais recorrentes (*recurrent neural networks* – RNN) [1],[9]. A Figura 6 apresenta um diagrama conceitual da função de ativação PAL2v.

Por ser baseada em uma lógica, os valores de μ e λ são limitados entre (0,1), por isso na figura aparece uma saturação entre esses dois valores, antes da operação da função PAL2v.





Figura 6 – Função de Ativação Neurônio PAL2v

Fonte: Adaptado de [1].



A função PAL2v de forma simplificada pode ser calculada conforme a seguir:

$$D = \sqrt{(1 - |\mu - \lambda|)^2 + (\mu + \lambda - 1)^2}$$


$$D = \begin{cases} 1 & D \geq 1 \\ D & 0 \leq D < 1 \end{cases}$$

$$\mu_{ER} = \begin{cases} \frac{2-D}{2} & (\mu - \lambda) > 0 \\ \frac{D}{2} & (\mu - \lambda) < 0 \\ 0 & (\mu - \lambda) = 0 \end{cases}$$

Interessante que a função de ativação PAL2v apresenta um comportamento dual. Se uma das entradas for mantida em 0.5, a saída será uma sigmoide. Do contrário a saída poderá saturar em 0.5, apresentando uma curva tipo retificadora não linear. A figura 7 apresenta a saída da função de ativação PAL2v, variando-se μ e mantendo-se λ constante. Já a Figura 8 apresenta a saída da função de ativação PAL2v mantendo-se μ constante e variando-se λ [8],[9].

**Figura 7** – Saída da Função PAL2v, variando-se μ .


Fonte: Adaptado de [1].

**Figura 8** – Saída da Função PAL2v, variando-se λ .

Fonte: Adaptado de [1].

O neurônio PAL2v apresentou melhor erro médio quadrático (mean square error – MSE) e menos ciclos de treinamento que RNAs equivalentes com funções sigmoide, tangente hiperbólica e LReLU para aplicações de identificação e controle de pêndulo invertido rotativo [8],[9], tanto com RNA convencional do tipo feed-forward, como em RNN [8],[9].

Uma comparação entre redes neurais utilizando as funções de ativação sigmoide, tanh, ReLU, LReLU e PAL2v em Matlab está disponível em [10].



2.7. Outras Funções de Ativação

Como dito anteriormente, existem muitas outras funções de ativação. Uma classe especial são as funções base radial (*radial basis functions* – RBF). Nessa categoria há uma grande quantidade de funções, tais como:

a. Gaussiana

$$\varphi(r) = e^{-(\varepsilon r)^2},$$

b. Multiquadrática

$$\varphi(r) = \sqrt{1 + (\varepsilon r)^2},$$

c. Inversa da Multiquadrática


$$\varphi(r) = \frac{1}{\sqrt{1 + (\varepsilon r)^2}},$$

As RBFs são aproximadores universais muito extremamente eficientes. O treinamento de rede neural RBF (RBF *neural network* – RBFNN) é mais rápido que funções de ativação do tipo sigmoide. A desvantagem da RBFNN está na sua complexidade, que aumenta conforme o crescimento de neurônios na camada oculta. Outro desafio da RBF está em sua estrutura algoritmo de treinamento, não permitindo modelar um sistema fortemente não linear [9]. Na literatura há uma grande variedade de RBFs propostas [11].

3. COMENTÁRIOS FINAIS

Este artigo procurou apresentar de forma sucinta os tipos de funções de ativação mais comuns utilizados em projetos de RNAs e suas características básicas, além de propostas que tem recebido atenção dos pesquisadores, como a função PAL2v e as RBFs.


A escolha da função de ativação da RNA passa por diversas questões tais como a complexidade da função, os algoritmos de aprendizagem da RNA, se o sistema resultará em “neurônios mortos”, se o processo de aprendizagem é suave ou apresenta dissipação do gradiente (*Vanishing Gradient*), qual o



poder computacional exigido para o treinamento da RNA, quantos neurônios e quantas camadas são necessários, entre outros fatores.

4. REFERÊNCIAS

- [1] DE CARVALHO JUNIOR, A. Identificação e Controle de Sistemas Dinâmicos com Rede Neural Paraconsistente. 2021. 196 p. Tese (Doutorado) – Programa de Engenharia Elétrica, Escola Politécnica, Universidade de São Paulo, São Paulo, 2021. Disponível em <https://www.teses.usp.br/teses/disponiveis/3/3142/tde-08102021-100149/pt-br.php>. Acessado em fevereiro 27, 2024.
- [2] TAFNER, M. A. O que são as Redes Neurais Artificiais, Revista Cerebro e Mente 2(5), 1998. Disponível em https://cerebromente.org.br/n05/tecnologia/ma_i.htm, acessado em fevereiro 27, 2024.
- [3] HAGAN, M. T.; DEMUTH, H. B.; BEALE, M. H.. Neural Network Design, Martin Hagan; 2º edition, 2014, 802 p. Disponível em <https://hagan.okstate.edu/NNDesign.pdf>, acessado em fevereiro 27, 2024.
- [4] DSA, Função de Ativação, Deep Learning Book, Data Science Academy. Disponível em <https://www.deeplearningbook.com.br/funcao-de-ativacao>, acessado em fevereiro 27, 2024.
- [5] SONODA, S.; MURATA, N. Neural network with unbounded activation functions is universal approximator. Applied and Computational Harmonic Analysis, Vol. 43, Issue 2, 2017, p. 233-268. DOI: 10.1016/j.acha.2015.12.005.
- [6] APICELLA, A.; DONNARUMMA, F.; ISGRÒ, F.; Prevete, R. A survey on modern trainable activation functions, Neural Networks, Volume 138, p. 14-32, 2021. DOI: 10.1016/j.neunet.2021.01.026.
- [7] LIU, X.; JIA, R.; LIU, Q.; ZHAO, C. AND SUN, H. Coastline Extraction Method Based on Convolutional Neural Networks—A Case Study of Jiaozhou Bay in Qingdao, China, in IEEE Access, vol. 7, p. 180281-180291, 2019. DOI: 10.1109/ACCESS.2019.2959662.
- [8] A. De Carvalho, J. F. Justo, B. A. Angélico, A. M. De Oliveira and J. I. d. S. Filho, “Rotary Inverted Pendulum Identification for Control by Paraconsistent Neural Network,” in IEEE Access, doi: 10.1109/ACCESS.2021.3080176.
- [9] Carvalho, A., Justo, J.F., Angélico, B.A. et al. Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946, DOI: 10.1016/j.asoc.2022.109927.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[10] CARVALHO, A. Paraconsistent Neural Network (PNN). MATLAB Central File Exchange. Retrieved June 13, 2023. Disponível em <https://www.mathworks.com/matlabcentral/fileexchange/130739-paraconsistent-neural-network-pnn>, acessado em fevereiro 27, 2024.

[11] DASH, Ch. Sanjeev Kumar; et al. Radial basis function neural networks: a topical state-of-the-art survey. Open Computer Science, vol. 6, no. 1, 2016, pp. 33-63. DOI: 10.1515/comp-2016-0005.

Elaborado Por: Dr. Arnaldo de Carvalho Junior

Publicado em: Fev 28, 2024

Disponível em: <https://eailab.labmax.org/2024/02/28/funcao-de-ativacao-o-nucleo-da-composicao-de-neuronios-artificiais/>. Acessado em: Nov 08, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


Post 5: Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML


1. INTRODUÇÃO

A inteligência artificial – IA (*artificial intelligence* – AI), segundo a Encyclopædia Britannica, é uma disciplina da ciência da computação que pesquisa a capacidade de um recurso computacional executar tarefas comumente associadas a seres inteligentes. O termo é amplo e geralmente aplicado ao desenvolvimento de sistemas e processos com capacidade de raciocinar, classificar, descobrir significado, generalizar ou aprender com experiências passadas [1]. A Inteligência Artificial pode ser dividida em 7 subcampos, conforme Figura 1 [2]:

- Aprendizado de máquina (*machine learning* – ML), Mineração de Dados e Grandes Dados (*Data Mining e Big Data*);
- Planejamento Automatizado;
- Sistemas Especialistas (*expert systems*);
- Processamento de Linguagem Natural (*natural language processing* – NLP);
- Reconhecimento de fala (*speech recognition*);
- Robótica;
- Visão Computacional (*computer vision*).

A ML é um ramo da IA (Figura 2), que se preocupa com a implementação de software de computador capaz de aprender autonomamente. Sistemas especialistas e programas de mineração de dados são as aplicações mais comuns para melhorar algoritmos através do uso de aprendizado de máquina [3].





EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Figura 1 – Subcampos da IA [2]




Figura 2 – Relação entre IA, ML e RNA.

As redes neurais artificiais – RNAs (*artificial neural networks* – ANN) são técnicas computacionais que apresentam um modelo matemático inspirado na estrutura neural de organismos inteligentes e que adquirem conhecimento através da experiência [4]. Essa estrutura é formada por neurônios artificiais, funções de ativação específicas, conforme apresentado em [5]. As RNAs desempenham papel fundamental nos algoritmos de ML e IA.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

2. TIPOS DE REDES NEURAIS ARTIFICIAIS

O aumento do poder computacional das últimas décadas permitiu uma rápida evolução e proposição de diferentes arquiteturas de RNAs para as mais variadas áreas do conhecimento humano [5]. A Figura 3 fornece uma ideia da variedade de configurações de RNAs [6].





Figura 3 – Tipos de RNAs [6].



Neste post serão apresentados as RNAs mais comumente empregadas em aplicações de ML.

2.1. Rede Neural Feedforward

A RNA do tipo feedforward foi uma das primeiras propostas, sendo uma das mais básicas. Nesta RNA, os dados ou a entrada fornecida viajam em uma única direção (forward). Os dados entram na RNA pela camada de entrada (input layer) e saem pela camada de saída (output layer), enquanto camadas ocultas (hidden layer) podem ou não existir. Logo, a rede neural feedforward (FNN) possui apenas uma onda propagada frontalmente sendo geralmente treinadas utilizando-se o método de retropropagação. Podem ser usadas para aproximação de funções e classificação de padrões [6].




Figura 4 – FNN.

2.2. Rede Neural de Base Radial

A rede neural de função base radial (*radial basis function neural network* – RBFNN) é um tipo de RNA feedforward que faz uso de funções de base radial como funções de ativação nos neurônios da camada oculta. Uma função de base radial é uma função de valor real, cujo valor depende apenas da distância da origem. Embora existam vários tipos de funções de base radial, a função Gaussiana é a mais frequentemente empregada, conforme Eq. 1, a seguir.

$$h_j(x) = \exp \left(- \|x - c_j\|^2 / \sigma_j^2 \right) \quad (1)$$



Onde (x) é o vetor de entrada, (c_j) é o centro da função Gaussiana e $h_j(x)$ a saída do neurônio j . A saída da rede é uma combinação linear de funções de base radial das entradas e parâmetros do neurônio. As RBFNN têm muitos usos, incluindo aproximação de funções, previsão de séries temporais, classificação e controle de sistema. O treinamento da RBFNN também é mais rápido do que a FNN utilizando neurônios baseados em sigmoide. Outras características da RBFNN incluem design fácil, boa generalização e robustez para ruído de entrada. Para problemas de aproximação de função, as RBFNN são especialmente recomendadas para superfícies com picos e vales regulares. Uma desvantagem da RBFNN é a sua complexidade, que aumenta à medida que o número de neurônios na camada oculta aumentam. Outro desafio da RBF está no seu algoritmo de treinamento e estrutura, não permitindo modelar um ambiente de sistema fortemente não linear [4].

2.3. Rede Neural Recorrente

A rede neural recorrente (*recurrent neural network* – RNN) difere da FNN pela direção do fluxo de informações entre as suas camadas. A RNN é uma rede neural artificial bidirecional, pois permite que a saída de alguns nós afete a entrada subsequente para os mesmos nós. Em outras palavras, as RNNs são redes com loops, permitindo que as informações persistam por mais tempo na rede. Sua capacidade de usar o estado interno (memória) para processar sequências arbitrárias de entradas torna as RNN aplicáveis a tarefas como reconhecimento de escrita manual conectada e não segmentada ou reconhecimento de fala.




Figura 5 – RNN.



As RNN são muito utilizadas para aplicações que utilizam séries temporais como entrada, como na modelagem e controle de sistemas não lineares, apesar das dificuldades maiores de treinamento do que redes FNN. Um exemplo é o desenvolvimento de um controle por modelo de referência (*model reference control* – MRC), utilizando RNN com neurônios PAL2v (*recurrent paraconsistente neural network* – RPNN) para prever a saída futura do controlador de um sistema dinâmico de pêndulo invertido rotativo, apresentando maior robustez e menor esforço do que um controle convencional, em [4].

2.4. LSTM

A rede neural de memória de longo e curto prazo (long short-term memory – LSTM) é uma variação de rede neural recorrente (RNN), que visa lidar com o problema do gradiente de fuga (*vanishing gradient*) presente em RNNs tradicionais. A unidade LSTM possui uma estrutura em cadeia composta por diferentes blocos de memória chamados células (cells), conforme a Figura 6. As células retêm a informação, enquanto os portões (gates) realizam a manipulação da memória. O cascadeamento de unidades LSTM foram a rede neural LSTM, conforme a Figura 7.





Figura 6 – unidade LSTM [8].






Figura 7 – Rede Neural LSTM [9].

As células retêm a informação, enquanto os portões (*gates*) realizam a manipulação da memória [8]. Os *gates* são:

a) Esqueça o portão (*Forget Gate*): As informações que não são mais úteis são removidas com o forget gate. A entrada no momento específico (x_t) e a saída da célula LSTM anterior (h_{t-1}) são alimentadas ao gate e multiplicadas por matrizes de peso, seguidas da adição de um *bias*, cujo resultado é aplicado a uma função de saída binária [5]. Se para um determinado estado de célula a saída for “0”, a informação é esquecida e para a saída “1”, a informação é retida para uso futuro.

b) Portão de entrada (*Input Gate*): A adição de informações úteis ao estado da célula é feita pelo *input gate*. Inicialmente, a informação é regulada usando a função sigmoide [5] que filtra os valores a serem lembrados usando as entradas x_t e, de maneira parecida com o *forget gate*. Então, mediante uma função de ativação tanh [5] um vetor é criado, fornecendo uma saída limitada a $[-1, +1]$, que contém todos os valores possíveis de x_t e h_{t-1} . Os valores do vetor e os valores regulados são multiplicados para obter as informações úteis.

c) Portão de saída (*Output Gate*): A tarefa de extrair informações úteis do estado da célula atual para ser apresentadas como uma saída é feita pelo *output gate*. Primeiro, um vetor é gerado aplicando a função de ativação tanh na célula. Então, a informação é regulada usando a função de ativação sigmoide que filtra os valores a serem lembrados usando as entradas x_t e h_{t-1} . Os valores do vetor e os valores regulados são multiplicados para serem enviados como uma saída e entrada para a próxima célula.

A LSTM é adequada para classificar, processar e prever séries temporais com intervalos de tempo de duração desconhecida, devido a sua capacidade de lembrar de valores em intervalos arbitrários. Além de aplicações que envolvem predição de saída futura, as redes LSTM têm sido utilizadas com sucesso na modelagem de linguagem, tradução de idiomas, legendas de imagens, geração de texto e *chatbots*.

2.5. Rede Neural Convolucional



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

A rede neural convolucional (*convolucional neural network* – CNN) é um tipo de FNN que aprende uma característica por meio de otimização de filtros. Gradientes de fuga e gradientes de explosão, vistos durante a retropropagação (*backpropagation*) em redes neurais clássicas, são evitados pelo uso de pesos regularizados em menos conexões. Por exemplo, para processar uma imagem de 100×100 pixels, seriam necessários 10.000 pesos para cada neurônio na camada totalmente conectada. No entanto, aplicando *kernels* de convolução em cascata, apenas 25 neurônios são necessários para processar blocos de tamanho 5×5 . Os recursos da camada superior são extraídos de janelas de contexto mais amplas, em comparação com os recursos da camada inferior.

Várias técnicas de convolução podem ser aplicadas, procurando extrair características específicas de um padrão 2D como contorno, contraste, objeto, etc. A Figura 8 apresenta um exemplo de convolução pela média, reduzindo uma matriz 4×4 (16 *pixels*) em uma matriz 2×2 (4 *pixels*).





Figura 8 – Convolução pela Média.

A Figura 9 apresenta uma arquitetura de CNN [10]. Pode-se observar que uma CNN é composta por uma ou mais camadas convolucionais (*hidden layers*), seguidas por uma ou mais camadas de neurônios totalmente conectados, para a etapa de classificação, como uma rede FNN padrão.





EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


Figura 9 – Arquitetura de CNN [10].


A arquitetura de uma CNN é projetada para aproveitar a estrutura 2D de uma imagem de entrada (ou de um sinal contínuo transformado em padrão 2D sendo invariantes à mudança (*shift invariant*) ou invariantes em espaço (*space invariant*). Outro benefício das CNNs é que elas são mais fáceis de treinar e possuem muito menos parâmetros do que redes totalmente conectadas com o mesmo número de unidades ocultas.

Aplicações de CNN incluem reconhecimento, segmentação e classificação de imagem e vídeo; sistemas de recomendação; análise de imagem médica; processamento de linguagem natural; interfaces cérebro-computador e séries temporais como financeiras, por exemplo. Uma ferramenta que utiliza CNN para identificação e classificação de imagens é o Edge Impulse [11]. Exemplos de aplicação podem ser observados nos artigos relacionados em [12].

2.6. Redes Neurais de Aprendizado Profundo

Redes Neurais de aprendizado profundo (*deep learning neural network* – DLNN) ou simplesmente redes neurais profundas (*deep neural network* – DNN) são redes neurais (FNN, RNN, CNN, entre outras) que possuem múltiplas camadas intermediárias. Embora possam existir diferentes topologias, a maioria dos modelos modernos de aprendizagem profunda são baseados em CNN. A Figura 10 apresenta uma arquitetura de DNN.





EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Figura 10 – Arquitetura de DNN [14].

O aprendizado profundo é uma classe de algoritmos de aprendizado de máquina que utiliza múltiplas camadas para extrair progressivamente recursos de nível superior da entrada bruta. Um exemplo de aplicação de DNN é no processamento de imagens, onde as camadas inferiores podem identificar bordas e contornos, enquanto as camadas superiores podem identificar os conceitos relevantes para um ser humano, como dígitos, letras ou rostos.


Como pode ser observado pela Figura 10, as DNNs são mais complexas que as redes neurais convencionais, com algoritmos mais densos e exigindo maior poder de processamento para o seu treinamento. Entretanto, as DNNs têm sido amplamente utilizadas no reconhecimento de imagens, processamento de linguagem natural, previsões financeiras, conversão de textos em imagens, entre outras aplicações. Uma boa revisão sobre algoritmos de aprendizado profundo e suas aplicações está disponível em [15].

3. CONSIDERAÇÕES FINAIS

As redes neurais artificiais são um poderoso instrumento para o sucesso do machine learning e da inteligência artificial. Este é um ramo da ciência da computação em acelerada evolução, com uma variedade virtualmente infinita de RNAs propostas. Este post apresentou algumas das arquiteturas de RNAs mais utilizadas, as suas características principais e potencial de aplicações em inteligência artificial. Em resumo, as FNN podem ser usadas em aproximação de funções e classificação de sinais, as RNN e suas variações (LSTM, por exemplo) utilizam séries temporais para previsão de saída futura. Já as CNN e suas variações são utilizadas em visão computacional, como no tratamento e classificação de imagens.

REFERÊNCIAS


[1] COPELAND, B.J. Artificial Intelligence. Encyclopedia Britannica, 1 Apr. 2024. Disponível em: <https://www.britannica.com/technology/artificial-intelligence>. Acessado em Abr 1, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- [2] KAYID, A. The role of Artificial Intelligence in future technology. Department of Computer Science, The German University in Cairo, 2020. Disponível em: [The-role-of-Artificial-Intelligence-in-future-technology.pdf \(researchgate.net\)](#)
- [3] SHINDE, P. P. and SHAH, S. A Review of Machine Learning and Deep Learning Applications, 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBE), Pune, India, 2018, pp. 1-6. DOI: 10.1109/ICCUBE.2018.8697857.
- [4] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. et al. Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946. DOI: 10.1016/j.asoc.2022.109927.
- [5] CARVALHO, A. Função de Ativação, o Núcleo da Composição de Neurônios Artificiais, EAILAB, IFSP, 2024. Disponível em: <https://eailab.labmax.org/2024/02/28/funcao-de-ativacao-o-nucleo-da-composicao-de-neuronios-artificiais/>
- [6] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. et al., Rotary Inverted Pendulum Identification for Control by Paraconsistent Neural Network, in IEEE Access, 2021. DOI: 10.1109/ACCESS.2021.3080176.
- [7] MONTAZER, G. A. et al. Radial basis function neural networks: A review. Computer Reviews. Journal, v. 1, n. 1, p. 52-74, 2018. Disponível em: <https://www.ise.ncsu.edu/fuzzy-neural/wp-content/uploads/sites/9/2022/08/RBFNN.pdf>
- [8] DEEP LEARNING BOOK. Capítulo 51 – Arquitetura de Redes Neurais Long Short Term Memory (LSTM). Disponível em: <https://www.deeplearningbook.com.br/arquitetura-de-redes-neurais-long-short-term-memory/>. Acessado em Abr 03, 2024.
- [9] OLAH, C. Understanding LSTM Networks, Colah's blog. Aug 2015. Disponível em: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>. Acessado em Abr 03, 2024.
- [10] YEOLA, C. Convolutional Neural Network (CNN) In Deep Learning, Feb, 2022. Disponível em: <https://python.plainenglish.io/convolution-neural-network-cnn-in-deep-learning-77f5ab457166>. Acessado em Abr 03, 2024.
- [11] EDGE IMPULSE. Build, train, optimize, ai for the edge. Edge Impulse. Disponível em: <https://edgeimpulse.com>. Acessado em abr 03, 2024.
- [12] CARVALHO, A. EAILAB inicia atividades com produção intensa de trabalhos. Nov, 2023. Disponível em: <https://eailab.labmax.org/2023/11/16/eailab-inicia-atividades-com-producao-intensa-de-trabalhos/>. Acessado em Abr 03, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[13] CHIEN, J-T. Chapter 7 – Deep Neural Network, Editor(s): Jen-Tzung Chien, Source Separation and Machine Learning, Academic Press, 2019, 259-320 p, ISBN 9780128177969, DOI: 10.1016/B978-0-12-804566-4.00019-X. Disponível em: <https://www.sciencedirect.com/science/article/pii/B978012804566400019X>.

[14] NIELSEN, M. A. Neural networks and deep learning. San Francisco, CA, USA: Determination press, 2015.


[15] SHINDE, Pramila P.; SHAH, Seema. A review of machine learning and deep learning applications. In: 2018 Fourth international conference on computing communication control and automation (ICCUBE). IEEE, 2018. p. 1-6. DOI: 10.1109/ICCUBE.2018.869.

Elaborado Por: Dr. Arnaldo de Carvalho Junior

Publicado em: Abr 03, 2024

Disponível em:

<https://eailab.labmax.org/2024/04/03/redes-neurais-artificiais-algoritmos-poderosos-para-aplicacoes-de-ia-e-ml/>. Acessado em Nov 08, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Post 6: Datasets de Acesso Livre para Projetos de IA!

A melhor forma de aprender o poder da inteligência artificial (IA) é criando projetos e aplicações com ela. O sucesso de um projeto de IA começa pela análise, seleção, tratamento e filtragem do conjunto de dados a serem utilizados no treinamento da IA. O tempo demandado nesta etapa permitirá economizar tempo nas etapas futuras do projeto, minimizar o uso de recursos computacionais e elevar o nível de acurácia da IA.

A seguir são relacionadas alguns dos repositórios de conjuntos de dados (*datasets*) de acesso livre para projetos de IA mais difundidos.

1. Datasets de Universidades

- a) UCI Machine Learning Repository – <https://archive.ics.uci.edu/datasets>
- b) Harvard Dataverse (Harvard University) – <https://data.harvard.edu/dataverse>
- c) Labelme (CSAIL – MIT)
<http://labelme.csail.mit.edu/Release3.0/browserTools/php/dataset.php>–
- d) Center of AI in Medicine & Imaging (Stanford University)
– <https://aimi.stanford.edu/shared-datasets>


2. Datasets de Governos

- a) Data .gov US – <https://data.gov/>
- b) Data .gov UK – <https://www.data.gov.uk/>
- c) European Data – <https://data.europa.eu/data/datasets?locale=en>
- d) Latin American Data Bank – <https://ropercenter.cornell.edu/latin-american-data-bank>
- e) Dados Abertos Brasil – <https://dados.gov.br/signin>

3. Datasets de Astronomia e Espaço

- a) Earth Data (NASA) – <https://www.earthdata.nasa.gov/>
- b) CERN Open Data Portal – <https://opendata.cern.ch/>

4. Datasets de Saúde



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- a) Health Data (USA) – <https://healthdata.gov/>
- b) Centers For Disease Control And Prevention (USA)
– <https://www.cdc.gov/datastatistics/index.html>
- c) Dataset for Health Care and Public Health (USA)
– <https://researchguides.dartmouth.edu/c.php?g=517073&p=6289098>
- d) Global Health Observatory Data Repository – World Health Organization (WHO)
– <https://apps.who.int/gho/data/node.home>
- e) National Library of Medicine (NIH – USA) – <https://medpix.nlm.nih.gov/home>

5. Datasets De Tópicos Variados

- a) ImageNet – <https://image-net.org/>
- b) Kaggle Datasets – <https://www.kaggle.com/datasets>
- c) Sigma Open Datasets – <https://sigma.ai/open-datasets/>
- d) OpenML – <https://www.openml.org/>
- e) Datahub .io – <https://datahub.io/collections>
- f) FiveThirtyEight – <https://data.fivethirtyeight.com/>
- g) Non-Commercial Datasets – <https://developer.imdb.com/non-commercial-datasets/>
- h) Google Dataset Search – <https://datasetsearch.research.google.com/>
- i) IBM Data Asset eXchange – <https://developer.ibm.com/exchanges/data/>
- j) AWS Open Data – https://aws.amazon.com/marketplace/search/results?trk=868d8747-614e-4d4d-9fb6-fd5ac02947a8&sc_channel=el&FULFILLMENT_OPTION_TYPE=DATA_EXCHANGE&CONTRACT_TYPE=OPEN_DATA_LICENSES&filters=FULFILLMENT_OPTION_TYPE%2CONTRACT_TYPE
- BD – <https://basedosdados.org/>

6. Datasets Temáticos

- a) Furnas Dataset (Electrical Power Transmission Lines) – <https://github.com/freds0/PTL-AI-Furnas-Dataset?tab=readme-ov-file>
- b) Nasdaq Data Link – <https://data.nasdaq.com/institutional-investors>
- c) Antarctic Datasets – <https://www.antarcticglaciers.org/antarctica-2/antarctic-datasets/>



EAILab


Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- d) BFI film industry statistics (UK) – <https://www.bfi.org.uk/industry-data-insights>
- e) NYC Taxi Trip Data – <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>
- f) FBI (USA) Crime Data Explorer – <https://cde.ucr.cjis.gov/LATEST/webapp/#/pages/home>

Elaborado Por: Dr. Arnaldo de Carvalho Junior

Publicado em: Jun 17, 2024

Disponível em: <https://eailab.labmax.org/2024/06/17/datasets-de-acesso-livre-para-projetos-de-ia/>. Acessado em Nov 08, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


Post 7: Excelentes Recursos para Estudar Aprendizado de Máquina

Neste *post* são apresentados excelentes recursos gratuitos para aprendizado de inteligência artificial (IA) e aprendizado de máquina (*machine learning* – ML) [1][3].

1. CURSOS, GUIAS E TUTORIAIS

- a) **TensorFlow**: tutoriais oficiais – <https://www.tensorflow.org/tutorials?hl=pt-br>
- b) **Scikit-learn**: Guias compreensivos e exemplos
– https://scikit-learn.org/stable/user_guide.html
- c) **Kaggle**: trilhas para estudar aprendizado de máquina (*machine learning* – ML), Python, Panda, etc. – <https://www.kaggle.com/learn>
- d) **Google AI**: como aprender a plataforma de inteligência artificial – IA (*artificial intelligence* – AI) do Google – <https://ai.google/build>
- e) **FreeCodeCamp**: curso de Python com ML
– <https://www.freecodecamp.org/learn/machine-learning-with-python/>
- f) **Stanford CS224N**: Aprendizado profundo (*deep learning* – DL) para processamento de linguagem natural (*natural language processing* NLP)
– <https://web.stanford.edu/class/cs224n/>
- g) **MIT OpenCourseWare**: introdução à DL – <https://ocw.mit.edu/courses/6-s191-introduction-to-deep-learning-january-iap-2020/>
- h) **TinyMLEdu**: iniciativa aberta de treinamento em TinyML, com plataforma Edge Impulse – <https://tinyml.seas.harvard.edu/>
- i) **Deep Learning Book**: plataforma online, em português, abordando conceitos de redes neurais, IA, ML, DL, em constante evolução [2]
– <https://www.deeplearningbook.com.br/>
- j) **Fast.ai**: DL prático para programadores – <https://course.fast.ai/>
- k) **DataCamp**: tutoriais gratuitos de Python e R – <https://www.datacamp.com/tutorial>
- l) **Canais do Youtube**:
 - a) **Sentdex**: tutoriais Python e ML – <https://www.youtube.com/user/sentdex>
 - b) **Corey Schafer**: Programação Python – <https://www.youtube.com/user/schafer5>

2. CURSOS DE IA NVIDIA



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Vale a pena revisitar o *post* anterior do EAILab, indicado na referência [3], onde são apresentados 8 cursos gratuitos disponibilizados pela NVIDIA. Alguns dos cursos requerem o uso dos módulos e placas de computador único da empresa.

3. LIVROS IA

O EAILab em sua seção “HotLinks” [4] mantém uma lista atualizada de livros de acesso gratuito para aprofundar os conhecimentos em inteligência artificial, aprendizado de máquina, programação Python, algoritmos de raciocínio com lógicas não clássicas (Paraconsistente, Fuzzy, ...), entre outros.

4. REFERÊNCIAS

[1] ALAM A. The Best Free Resources to Master Machine Learning. Art of Data Science, 2024.

Disponível em: https://media.licdn.com/dms/image/D5622AQHbF_FxS0qniQ/feedshare-shrink_800/0/1720438696292?e=1723075200&v=beta&t=4Rulg0quCep9a4wOBjMtPHPqxV4DI-AN58jGc_E02Js.

Acessado em Julho 08, 2024.

[2] DSA. Deep Learning Book, Data Science Academy (DSA), 2024. Disponível em: <https://www.deeplearningbook.com.br/>. Acessado em Julho 8, 2024.

[3] CARVALHO JUNIOR, A. 8 Excelentes cursos gratuitos da NVIDIA, para entrar no universo da Inteligência Artificial. EAILab Posts, Abril 2, 2024. Disponível em: <https://eailab.labmax.org/2024/04/02/8-excelentes-cursos-gratuitos-da-nvidia-para-entrar-no-universo-da-inteligencia-artificial/>. Acessado em Jul 8, 2024.

[4] CARVALHO JUNIOR, A. Hot Links – Free Ebooks, EAILab, 2024. Disponível em: <https://eailab.labmax.org/hot-links/>. Acessado em Julho 8, 2024.

Preparado por: Dr. Arnaldo de Carvalho Junior

Publicado em: Jul 08, 2024

Disponível em: <https://eailab.labmax.org/2024/07/08/excelentes-recursos-para-estudar-aprendizado-de-maquina/>. Acessado em Nov 08, 2024.


**Post 8: Principais Algoritmos Utilizados em Inteligência Artificial****1. INTRODUÇÃO**


Conforme apresentado em postagens anteriores [1],[2] a Inteligência Artificial (IA) é uma área da ciência da computação que desenvolve sistemas capazes de executar tarefas normalmente realizadas por seres inteligentes.

A IA tem sido utilizada nas mais diversas áreas do conhecimento humano, para raciocinar, identificar, classificar, descobrir significado, generalizar, aprender por experiência, tomar decisão, controlar e realizar previsões ou prognósticos [1].

2. PRINCIPAIS ALGORITMOS DE IA

Diferentes técnicas matemáticas, estatísticas e computacionais são utilizadas para o desenvolvimento de soluções de IA, conforme a Figura 1. Um verdadeiro arsenal, ou “cinto de utilidades”, de diferentes recursos estão à disposição do pesquisador em IA. Esses algoritmos podem ser utilizados de forma isolada ou combinados, em soluções híbridas, para uma melhor performance.

**Figura 1 – Algoritmos de IA e ML****Fonte: O Autor (2024)**



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

A seguir são relacionados os principais algoritmos utilizados em IA [3],[4]. Para saber mais, explore as referências indicadas em cada um dos algoritmos.


2.1. Regressão Linear (*Linear Regression* – LR): Um dos mais conhecidos algoritmos de estatística e muito utilizado no aprendizado de máquinas (*machine learning* – ML). A LR cria um modelo para a compreensão da relação entre variáveis numéricas de entrada e saída. Isso permite que a LR seja utilizada para prever resultados com base em dados anteriores [5].

2.2. Regressão Logística (*Logistic Regression* – LR): É um modelo estatístico utilizado que analisa a relação entre 2 fatores de dados. A regressão logística é um algoritmo de ML supervisionado, usado para tarefas de classificação, cujo objetivo é prever a probabilidade de uma instância pertencer ou não a uma determinada classe. É o método estatístico preferido para problemas de classificação binária (problemas com dois valores de classe).[6].

2.3. Aumento Gradual (*Gradient Boosting* – GB): É uma técnica em melhora predições através de erros passados em passos pequenos. O GB é uma das técnicas mais poderosas para a construção de modelos preditivos [7].

2.4. Bayes Ingênuos (*Naive Bayes* – NB): É um algoritmo simples porém poderoso para modelagem preditiva. O Teorema de Bayes fornece uma maneira de calcular a probabilidade de uma hipótese dado o conhecimento prévio [8].

2.5. Redes Bayesianas (*Bayesian Networks* – BN): Também fundamentado no Teorema de Bayes, utiliza probabilidade para realizar predição considerando diferentes fatores. as Redes Bayesianas fornecem uma ferramenta útil para visualizar o modelo probabilístico para um domínio, revisar todas as relações entre as variáveis aleatórias, e razão sobre probabilidades causais para cenários dadas as evidências disponíveis [9].



2.6. Modelo de Markov (Markov *Model* – MM): São uma classe de Modelos Gráficos Probabilísticos (*probabilistic graph models* – PGM) que representam processos dinâmicos, ou seja, um processo que não é estático, mas sim que muda com o tempo. Em particular, preocupa-se mais sobre como o estado (*state*) de um processo muda com o tempo [8]. Em conjunto com a amostragem de Monte Carlo, a cadeia de Markov fornece uma classe de algoritmos para amostragem aleatória sistemática a partir de distribuições de probabilidade de alta dimensão. Ao contrário dos métodos de amostragem de Monte Carlo que são capazes de extrair amostras independentes da distribuição, os métodos de Monte Carlo da Cadeia de Markov coletam amostras onde a próxima amostra depende da amostra existente, chamada de Cadeia de Markov. Isso permite que os algoritmos se restrinjam na quantidade que está sendo aproximada da distribuição, mesmo com um grande número de variáveis aleatórias [10].

2.7. Árvores de Decisão (Decision Tree – DT): é um algoritmo útil de aprendizado de máquina usado para tarefas de regressão e classificação. O nome “Árvore de Decisão” vem do fato de que o algoritmo continua dividindo o conjunto de dados em porções cada vez menores até que os dados sejam divididos em instâncias únicas, que são classificadas, ao tomar decisões do tipo sim ou não em cada instância. Ao visualizar a estrutura dos resultados do algoritmo, a maneira como as categorias são divididas se parecerem com uma árvore e muitas folhas [12],[13].

2.8. Raciocínio por Inferência (Reasoning by Inferences): Lógicas não clássicas como lógica difusa (Fuzzy) [14], paraconsistente e suas variações como a lógica paraconsistente anotada de 2 valores (PAL2v) [15],[16],[17],[18], permitem a construção de algoritmos para tomada de decisão quando informações não estão claramente definidas. Algoritmos PAL2v de referência estão disponíveis em [clikando aqui](#).

2.9. Redes Neurais Artificiais (Artificial Neural Networks – ANN): redes de neurônios artificiais baseados no cérebro biológico, que aprende por exemplos [1]. Cada neurônio é bloco elementar da rede neural, formado por um conjunto de entradas e saídas que funcionam como sinapses da ANN [5],[6],[7]. O sinal que atravessa uma sinapse pode ter



um peso (reforço) maior ou menor ao entrar em um neurônio, dependendo do aprendizado da rede neural. As entradas de cada neurônio são combinadas e aplicadas a uma função de ativação, que processará e apresentará o resultado em sua saída [2],[3]. As ANNs já foram abordadas em postagem anterior [1].

2.10. Redes Neurais Recorrentes (*Recurrent Neural Networks – RNN*): tipo de rede neural, cuja arquitetura possui realimentações internas, funcionando como efeito memória, permitindo que a RNN entenda sequências como texto e séries temporais de dados [1]. As RNAs podem assim, serem utilizadas na predição e controle de sistemas [6], [7]. Uma evolução das RNAs são as redes de Memória de Termo Curto Longo (*long short term memory – LSTM*) e Unidades de Portas Recorrentes (*gated recurrent units – GRU*). As redes LSTM e GRU já foram abordadas em postagem anterior [1].




Figura 2 – Conceito de RNN (a) e Unidade LSTM (b).

Fonte: Adaptado de [1].



2.11. Redes Neurais Convolucionais (*Convolutional Neural Networks – CNN*): são redes neurais especializadas, que permitem computadores ver e entender imagens [1],[2], [3],[19]. Neste tipo de ANN, **técnicas de convolução** são aplicadas na matriz de dados (como a matriz de pixels de uma imagem), antes da entrada na ANN, de modo a destacar ou realçar determinadas características como objeto, cores, contraste, contornos, etc. São muito utilizadas na identificação e classificação de padrões de imagens. Um exemplo de arquitetura pode ser visto na Figura 3.





Figura 3 – Arquitetura de Rede Neural Convolucional.

Fonte: Adaptado de [20].

2.12. Conjunto de Significados K (*K-Means Clustering*): algoritmo que agrupa itens semelhantes, sem uma definição prévia. É frequentemente usado como uma técnica de análise de dados para descobrir padrões interessantes em dados, como grupos de clientes com base em seu comportamento [21].

2.13. Análise de Componentes Principais (*Principal Component Analysis – PCA*): A PCA é uma técnica de aprendizado de máquina não supervisionada que empacota dados importantes em um pequeno espaço. É usada principalmente na análise de componentes principais seja a redução da dimensionalidade. Além de usar o PCA como técnica de preparação de dados, também pode-se utilizá-la para ajudar a visualizar dados. Com os dados visualizados, é mais fácil obter algumas ideias e decidir sobre a próxima etapa em modelos de aprendizado de máquina [22].




2.14. Auto-Codificadores (*AutoEncoders*): Autoencoders (AE) são redes neurais que visam copiar suas entradas para suas saídas. Especificamente, projetaremos uma arquitetura de rede neural de modo a impor um gargalo na rede que força uma representação de conhecimento compactada da entrada original. Se houver algum tipo de estrutura nos dados (ou seja, correlações entre os recursos de entrada), essa estrutura poderá ser aprendida e consequentemente aproveitada ao forçar a entrada através do gargalo da rede. Assim, o AE comprime e depois reconstrói imagens [23].

2.15. Aprendizagem de Reforço (*Reinforcement Learning* – **RL):** aprende com recompensas, ou seja, o computador é recompensado por boas ações e erros são corrigidos [24].

2.16. Aprendizado Q (*Q-Learning*): encontra o melhor caminho em um labirinto, através da exploração e recompensa. O processo de Q-Learning cria uma matriz (tabela) exata para o agente a qual ele “consulta” para maximizar sua recompensa a longo prazo durante seu aprendizado [25].

2.17. Vizinhos Mais Próximos (*K Nearest Neighbors* – **K-NN):** encontra vizinhos mais próximos para fazer previsões. As previsões são feitas para uma nova instância (x) pesquisando todo o conjunto de treinamento para as instâncias mais semelhantes (os vizinhos) e resumindo a variável de saída para essas instâncias K. Para regressão, essa pode ser a variável de saída média, na classificação, esse pode ser o valor do modo (ou mais comum) [26].

2.18. Florestas Aleatórias (*Randon Forest* – **RF):** combina várias respostas para precisão. O RF utiliza um conjunto de Árvores de Decisão para realizar tarefas de classificação ou regressão. O método da Floresta Aleatória, que se dá pela combinação de outros métodos são denominados como ensemble. O conceito fundamental das Florestas Aleatórias é a sabedoria das multidões: um número grande de modelos não correlacionados, no caso as árvores, operando em conjunto performarão melhor do que cada modelo individual [27].



2.19. Máquina Vetorial de Suporte (*Support Vector Machine* – **SVM):** Máquinas de vetores de suporte são um conjunto de métodos de aprendizado supervisionado utilizados para classificação, regressão, e detecção de outliers. Todas essas são tarefas comuns em aprendizado de máquina. Um classificador SVM linear simples funciona criando uma linha reta entre duas classes. Isso significa que todos os pontos de dados de um lado da linha representarão uma categoria, e os pontos de dados do outro lado da linha serão colocados em uma categoria diferente. Isso significa que pode haver um número infinito de linhas para escolher [28].

2.20. Algoritmos Genéticos (*Genetic Algorithm* – **GA):** O GA é um metaheurístico inspirado no processo de seleção natural que pertence à maior classe de algoritmos evolutivos (EA). Ele evolui na solução ao combinar as melhores opções através do tempo. Os algoritmos genéticos são comumente usados para gerar soluções de alta qualidade para otimização e problemas de pesquisa, confiando em operadores biologicamente inspirados, como mutação, *crossover* e seleção. Exemplos de aplicações de GA incluem otimizar as árvores de decisão para melhor desempenho, resolver quebra-cabeças, otimização de hiperparâmetro, inferência causal, etc. [29].

2.21. Redes Transformadoras (*Transformer Networks* – **TN):** As redes *Transformer* vem ganhando bastante interesse entre pesquisadores nos últimos anos. O *Transformer* é um modelo de aprendizado profundo introduzido em 2017 que utiliza o mecanismo de atenção, pesando a influência de diferentes partes dos dados de entrada. O *Transformer* é uma arquitetura que visa resolver tarefas sequência a sequência enquanto lida com dependências de longo alcance com facilidade. Ele se baseia inteiramente em auto-atenção (*Self-Attention*) para computar as representações de sua entrada e saída sem usar RNNs (Redes Neurais Recorrentes) alinhadas em sequência ou convolução. São algoritmos complexos e que exigem grande capacidade computacional. As redes *Transformer* tem sido utilizadas no processamento de linguagem natural e análise de séries temporais [30]. A Figura 4 apresenta um modelo da arquitetura de Rede *Transformer* [31].





Figura 4 – Modelo de Arquitetura do Algoritmo de Rede Transformer

Fonte: Adaptado de [31]

3. CONCLUSÃO

Esta postagem procurou agrupar e relacionar as principais classes de algoritmos de IA e ML. Para cada algoritmo relacionado, há inúmeras variações e adaptações. Como pôde ser verificado, há dezenas de técnicas, cada uma apresenta vantagens, desvantagens e principais usos. É importante que o pesquisador de IA conheça fundamentos de matemática, como álgebra linear, probabilidade e estatística e cálculo, bem como programação de modo a avaliar a melhor ferramenta de IA para cada desafio que se deseja resolver. Há inúmeras bibliotecas disponíveis para Python, para a maioria dos algoritmos de IA, o que pode acelerar o desenvolvimento de novas ferramentas e aplicações.

4. REFERÊNCIAS



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


- [1] CARVALHO, Arnaldo. Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML. EAILAB, IFSP, Publicado em Abril 03, 2024. Disponível em <<https://eailab.labmax.org/2024/04/03/redes-neurais-artificiais-algoritmos-poderosos-para-aplicacoes-de-ia-e-ml/>>. Acessado em Jun 20, 2024.
- [2] CARVALHO, Arnaldo. 10 Tendências de Aplicação de Inteligência Artificial em 2024! EAILAB, IFSP, Publicado em Nov 28, 2023. Disponível em <<https://eailab.labmax.org/2023/11/28/10-tendencias-de-aplicacao-de-inteligencia-artificial-em-2024/>>. Acessado em Jun 20, 2024.
- [3] RAY, Susmita. A quick review of machine learning algorithms. In: 2019 International conference on machine learning, big data, cloud and parallel computing (COMITCon). IEEE, 2019. p. 35-39.
- [4] MAHESH, Batta. Machine learning algorithms- A Review. International Journal of Science and Research (IJSR).[Internet], v. 9, n. 1, p. 381-386, 2020.
- [5] BROWNLEE, J. Linear Regression for Machine Learning, Mahine Learning Mastery, Dez 6, 2023. Disponível em <<https://machinelearningmastery.com/linear-regression-for-machine-learning/>>. Acessado em Jul 7, 2024.
- [6] BROWNLEE, J. Logistic Regression for Machine Learning, Mahine Learning Mastery, Dez 6, 2023. Disponível em <<https://machinelearningmastery.com/logistic-regression-for-machine-learning/>>. Acessado em Jul 7, 2024.
- [7] BROWNLEE, J. A Gentle Introduction to the Gradient Boosting Algorithm for Machine Learning, Ago 15, 2020. Disponível em <<https://machinelearningmastery.com/gentle-introduction-gradient-boosting-algorithm-machine-learning/>>. Acessado em Jul 7, 2024.
- [8] BROWNLEE, J. Naive Bayes for Machine Learning, Ago 15, 2020. Disponível em <<https://machinelearningmastery.com/naive-bayes-for-machine-learning/>>. Acessado em Jul 7, 2024.
- [9] BROWNLEE, J. A Gentle Introduction to Bayesian Belief Networks, Set 25, 2019. Disponível em <<https://machinelearningmastery.com/introduction-to-bayesian-belief-networks/>>. Acessado em Jul 7, 2024.
- [10] LAWHATRE, P. Gentle Introduction to Markov Chain, Machine Learnig Plus, 2024. Disponível em: <<https://www.machinelearningplus.com/markov-chain/>>. Acessado em Jul 7, 2024.




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- [11] BROWNLEE, J. A Gentle Introduction to Markov Chain Monte Carlo for Probability, Set 25, 2019. Disponível em <<https://machinelearningmastery.com/markov-chain-monte-carlo-for-probability/>>. Acessado em Jul 7, 2024.
- [12] CHARBUTY, Bahzad; ABDULAZEEZ, Adnan. Classification based on decision tree algorithm for machine learning. Journal of Applied Science and Technology Trends, v. 2, n. 01, p. 20-28, 2021.
- [13] SOMVANSI, Madan *et al.* A review of machine learning techniques using decision tree and support vector machine. In: 2016 international conference on computing communication control and automation (ICCUBEA). IEEE, 2016. p. 1-7.
- [14] HÜLLERMEIER, Eyke. Fuzzy methods in machine learning and data mining: Status and prospects. Fuzzy sets and Systems, v. 156, n. 3, p. 387-406, 2005.
- [15] CARVALHO, Arnaldo. Função de Ativação, o Núcleo da Composição de Neurônios Artificiais, EILAB, IFSP, 2024. Disponível em: <<https://eailab.labmax.org/2024/02/28/funcao-de-ativacao-o-nucleo-da-composicao-de-neuronios-artificiais/>>. Acessado em Jun 20, 2024.
- [16] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. *et al.* Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946. DOI: 10.1016/j.asoc.2022.109927.
- [17] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. *et al.*, Rotary Inverted Pendulum Identification for Control by Paraconsistent Neural Network, in IEEE Access, 2021. DOI: 10.1109/ACCESS.2021.3080176.
- [18] DE CARVALHO JUNIOR, Arnaldo *et al.* A comprehensive review on paraconsistent annotated evidential logic: Algorithms, Applications, and Perspectives. Engineering Applications of Artificial Intelligence, v. 127, p. 107342, 2024.
- [19] GUPTA, Jaya; PATHAK, Sunil; KUMAR, Gireesh. Deep learning (CNN) and transfer learning: a review. In: Journal of Physics: Conference Series. IOP Publishing, 2022. p. 012029.
- [20] SAHA, S. A Comprehensive Guide to Convolutional Neural Networks — the ELI5 way, Medium, Dez 2018. Disponível em <<https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53>>. Acessado em Jul 12, 2024.



- [21] BROWNLEE, J. 10 Clustering Algorithms With Python, Mahine Learning Mastery, Ago 20, 2020. Disponível em <<https://machinelearningmastery.com/clustering-algorithms-with-python/>>. Acessado em Jul 7, 2024.
- [22] TAM, A. 10 Principal Component Analysis for Visualization, Mahine Learning Mastery, Out 27, 2021. Disponível em <<https://machinelearningmastery.com/principal-component-analysis-for-visualization/>>. Acessado em Jul 7, 2024.
- [23] DEEP LEARNING BOOK, Capítulo 58 – Introdução aos Autoencoders, Data Science Academy, 2022. Disponível em <<https://www.deeplearningbook.com.br/introducao-aos-autoencoders/>>. Acessado em Jul 12, 2024.
- [24] DEEP LEARNING BOOK, Capítulo 62 – O Que é Aprendizagem Por Reforço?, Data Science Academy, 2022. Disponível em <<https://www.deeplearningbook.com.br/o-que-e-aprendizagem-por-reforco/>>. Acessado em Jul 12, 2024.
- [25] DEEP LEARNING BOOK, Capítulo 70 – Deep Q-Network e Processos de Decisão de Markov, Data Science Academy, 2022. Disponível em <<https://www.deeplearningbook.com.br/deep-q-network-e-processos-de-decisao-de-markov/>>. Acessado em Jul 12, 2024.
- [26] BROWNLEE, J. K-Nearest Neighbors for Machine Learning, Ago 15, 2020. Disponível em <<https://machinelearningmastery.com/markov-chain-monte-carlo-for-probability/>>. Acessado em Jul 7, 2024.
- [27] KUBRUSLY, J. Introdução ao Machine Learning – Capítulo 4 Floresta Aleatória, Laboratório de Estatística, Universidade Federal Fluminense, 2023. Disponível em: <https://bookdown.org/jessicakubrusly/intr-machine-learning-i/_book/cap-floresta.html>. Acessado em Jul 12, 2024.
- [28] SOUZA, I. C. N. Tutorial de aprendizado de máquina SVM – o que é o algoritmo de máquina de vetores de suporte, explicado com exemplos de códigos. FreeCodeCamp, Jun 2024. Disponível em: <<https://www.freecodecamp.org/portuguese/news/tutorial-de-aprendizado-de-maquina-svm/>>. Acessado em Jul 12, 2024.
- [29] BROWNLEE, J. Simple Genetic Algorithm From Scratch in Python, Mahine Learning Mastery, Out 12, 2021. Disponível em <<https://machinelearningmastery.com/simple-genetic-algorithm-from-scratch-in-python/>>. Acessado em Jul 7, 2024.
- [30] DEEP LEARNING BOOK, Capítulo 85 – Transformadores – O Estado da Arte em Processamento de Linguagem Natural, Data Science Academy, 2022. Disponível em



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

<<https://www.deeplearningbook.com.br/transformadores-o-estado-da-arte-em-processamento-de-linguagem-natural/>>. Acessado em Jul 12, 2024.

[31] ANKIT, U. Transformer Neural Network: Step-By-Step Breakdown of the Beast. Toward Data Science, Medium, Abr 2020. Disponível em: <<https://towardsdatascience.com/transformer-neural-network-step-by-step-breakdown-of-the-beast-b3e096dc857f>>. Acessado em Jul 12, 2024.

Elaborado Por: Dr. Arnaldo de Carvalho Junior

Publicado em: Jul 13, 2024

Disponível em: <https://eailab.labmax.org/2024/07/08/excelentes-recursos-para-estudar-aprendizado-de-maquina/>. Acessdo em Nov 08, 2024.



Post 9: O Poder Das CNNs Em Aplicações de ML Envolvendo Identificação e Classificação de Imagens

1. O QUE É UMA CNN?

Uma rede neural convolucional (convolutional neural network – CNN) é um tipo especializado de algoritmo de aprendizado profundo (deep learning) projetado para processar e analisar dados visuais. É muito utilizada em aplicações de aprendizado de máquina (machine learning – ML) [1]. Inspirados no córtex visual humano, as CNNs usam operações de convolução para extrair recursos e identificar padrões dentro das imagens. A CNN é um tipo de rede neural do tipo “olhar para a frente” (feedforward neural network – FNN) que aprende uma característica por meio de otimização de filtros [1]. Essa arquitetura permite que as CNNs interpretem e classifiquem imagens com eficiência, tornando-as inestimáveis em aplicativos de visão computacional [2]. A Figura 1 apresenta uma arquitetura de uma CNN.




Figura 1 – Arquitetura de CNN

Fonte: Adaptado de [2].

2. CAMADAS-CHAVE DA CNN

a) Camada convolucional (*convolutional layer*): este é o bloco de construção principal de uma CNN, onde os filtros (*kernels*) deslizam sobre a imagem de entrada para detectar recursos (*features*) como bordas, contrastes e texturas. A saída é um mapa de recursos que destaca esses recursos detectados. A Figura 2 apresenta as atividades da camada convolucional. Já a sequência de imagens da Figura 3 apresenta um exemplo do processo convolucional. Vários filtros de convolução podem ser aplicados, procurando-se extrair características específicas de um padrão 2D como contorno, contraste, objeto, etc [1].




Figura 2 – Série de Convoluções como Forma de Extração de Características da Imagem, pela CNN.

Fonte: Adaptado de [3].




Figura 3 - Sequência de Convolução.

Fonte: Adaptado de [4].

b) Camada de agrupamento (*pooling layer*): Após a camada convolucional, as camadas de agrupamento diminuem os mapas de recursos, reduzindo suas dimensões espaciais. Esta etapa diminui a complexidade computacional e ajuda a evitar o excesso de ajuste. O máximo de pool, que seleciona o valor máximo de uma região, é uma técnica comum usada aqui.

c) Camada de ativação da unidade retificadora linear (*rectified linear unit* – ReLU): A ReLU introduz a não linearidade no modelo, permitindo que ele aprenda padrões e relacionamentos complexos nos dados. A ReLU é uma das funções de ativação mais utilizadas atualmente em redes



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

neurais pela sua rapidez no processo de aprendizagem [5]. Na função ReLU, se a entrada for negativa, ela será convertida em zero e o neurônio não será ativado. Isso significa que, ao mesmo tempo, apenas alguns neurônios são ativados, tornando a rede esparsa, eficiente e de computação fácil. Essa vantagem também pode ser considerada uma desvantagem, pois os neurônios utilizando ReLU tendem a “morrer” durante o treinamento, causando a saída do neurônio iniciar a produzir apenas zeros [6]. Para evitar isso, uma variação da ReLU, chamada Leaky-ReLU (LReLU) foi desenvolvida, que aplica uma ligeira inclinação na função de ativação para valores menores que zero [7]. A Figura 4 apresenta as funções de ativação ReLU e sua variante Leaky-ReLU [8].





Figura 4 – Funções de Ativação ReLU e Leaky-ReLU.

Fonte: Adaptado de [8].



d) Camada totalmente conectada (*fully connected layer*): Nos estágios finais, as camadas totalmente conectadas usam os recursos de alto nível aprendidos pelas camadas anteriores para fazer previsões. Cada neurônio nessas camadas está conectado a todos os neurônios da camada anterior, integrando todos os recursos extraídos para produzir a saída final.

3. CNN X ANN

Embora as redes neurais artificiais (*artificial neural networks* – ANNs) sejam versáteis [1], elas lutam com dados de alta dimensão, como imagens devido à sua natureza totalmente conectada. As CNNs, no entanto, são projetadas especificamente para lidar com estruturas de dados semelhantes à grade (*grid*) ou matriz, tornando-as altamente eficientes para o processamento de imagens. Sua capacidade de capturar hierarquias espaciais e padrões locais os diferencia das ANNs tradicionais.

3.1. A ANN NÃO SERVE PARA PROCESSAR IMAGENS?


As ANNs exigem engenharia extensa de recursos e lutam com a alta dimensionalidade dos dados da imagem. Por outro lado, as CNNs aprendem automaticamente representações hierárquicas de recursos, melhorando significativamente a precisão e reduzindo a necessidade de intervenção manual.

4. APLICAÇÕES DA CNN

As CNNs transformaram indústrias com sua alta precisão em tarefas relacionadas à imagem. Elas são amplamente utilizadas em:

- Análise de imagem médica: auxiliando no diagnóstico de doenças através do reconhecimento de imagem.
- Veículos autônomos: permitindo a detecção de objetos e o entendimento da cena.
- Reconhecimento facial: alimentando sistemas de segurança e autenticação.
- Além das aplicações que envolvem imagens, existem pesquisas utilizando CNNs também em processamento de linguagem natural (*natural language processing* – NLP), interfaces cérebro-computador e séries temporais como financeiras, por exemplo [1].

5. CONCLUSÃO



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

A arquitetura de uma CNN é projetada para aproveitar a estrutura 2D de uma imagem de entrada. Outro benefício das CNNs é que elas são mais fáceis de treinar e possuem muito menos parâmetros do que redes totalmente conectadas com o mesmo número de unidades ocultas.

As CNNs continuam a ultrapassar os limites do que é possível na aprendizagem profunda, oferecendo soluções poderosas para desafios complexos de dados visuais.

REFERÊNCIAS

[1] CARVALHO JUNIOR, A. Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML. EAILab Posts. 2024. Disponível em: <<https://eailab.labmax.org/2024/04/03/redes-neurais-artificiais-algoritmos-poderosos-para-aplicacoes-de-ia-e-ml/>>. Acessado em Ago 13, 2024.

[2] ANALOG DEVICES. What Is Machine Learning? Part 1 – Introduction to convolutional neural networks, 2024. Disponível em: <<https://www.radiolocman.com/review/article.html?di=664841>>. Acessado em Nov 1, 2024.

[3] SUPERANNOTATE, Convolutional Neural Networks: 1998-2023 Overview, Super Annotate (Blog), 2023. Disponível em: <<https://www.superannotate.com/blog/guide-to-convolutional-neural-networks>>. Acessado em Ago 13, 2024.

[4] SCIENTISTCAFE, 12.2 Convolutional Neural Network, Scientist Cafe (Blog), 2023. Disponível em: <<https://scientistcafe.com/ids/convolutional-neural-network.html>>. Acessado em Ago 13, 2024.

[5] CARVALHO JUNIOR, A. Função de Ativação, o Núcleo da Composição de Neurônios Artificiais. EAILab Posts. 2024. Disponível em: <<https://eailab.labmax.org/2024/02/28/funcao-de-ativacao-o-nucleo-da-composicao-de-neuronios-artificiais/>>. Acessado em Ago 13, 2024.

[6] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. et al., Rotary Inverted Pendulum Identification for Control by Paraconsistent Neural Network, in IEEE Access, 2021. DOI: 10.1109/ACCESS.2021.3080176.

[7] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. et al. Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946. DOI: 10.1016/j.asoc.2022.109927.

[8] LIU, D. A Practical Guide to ReLU. Medium, 2017. Disponível em: <<https://medium.com/@danqing/a-practical-guide-to-relu-b83ca804f1f7>>. Acessado em Ago 13, 2024.

Elaborado Por: Dr. Arnaldo de Carvalho Junior



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Publicado em: Ago 13, 2024

Disponível em: <https://eailab.labmax.org/2024/08/13/o-poder-das-cnns-em-aplicacoes-de-ml-envolvendo-identificacao-e-classificacao-de-imagens/>. Acessado em Nov 08, 2024.



Post 10: Roteiro Para Criação de Dataset de Imagens Para modelos de Aprendizagem Profunda

Uma das etapas mais importantes para se criar um modelo de aprendizagem profunda (*deep learning* – DL) é criar um *dataset* (conjunto de dados) de imagens em grande escala para treinar o modelo.


Mas como coletar, rotular e armazenar imagens de maneira eficiente e eficaz?

Neste post será abordado o passo a passo do processo de criação do *dataset* de imagem, incluindo desde o planejamento e preparação até os detalhes de anotação e organização, conforme a Figura 1.



Figura 1 – Fluxograma de Criação de Dataset de Imagens.
Fonte: Autoria Própria (2024).

1. COMPREENDENDO AS NECESSIDADES DO DATASET DE IMAGEM



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Quando se trata de construir um *dataset* de imagem, o primeiro passo é entender o propósito que o *dataset* servirá. Se o propósito é para pesquisa, um modelo de inteligência artificial (IA) ou DL, ou diversão, saber o propósito ajudará a determinar que tipo de dados são necessários e quanto deles.

Por exemplo, se o objetivo do *dataset* de imagem for um projeto de pesquisa, os dados devem ser de alta qualidade e ter um nível específico de detalhe que auxiliará no estudo.

Por outro lado, se o propósito é apenas para diversão, então o *dataset* pode ser mais relaxado, variado e aberto. Se um modelo de IA ou DL usar o *dataset*, ele deverá ser **estruturado** para facilitar o aprendizado e o **reconhecimento de padrões** nas imagens pelo sistema. Portanto, a clareza sobre o propósito das imagens é crucial na construção de um *dataset* bem-sucedido e eficaz.

Ao construir um dataset de imagem, uma das primeiras coisas a considerar é o tamanho e a complexidade dos dados. Como tal, é importante determinar quantas imagens são necessárias e quais tipos de imagens atendem às necessidades.

É importante lembrar que o tipo de imagens no *dataset* impactará significativamente o quão **preciso** e **eficaz** será qualquer modelo de aprendizado de máquina (*machine learning* – ML) que se treinar nele.


Portanto, gastar tempo pesquisando e planejando o tamanho e a complexidade ideais do *dataset* de imagens é crucial para obter resultados confiáveis.

Em seguida, ao fazer um *dataset* de imagem, é preciso considerar os requisitos de qualidade que as imagens precisam atender para fornecer resultados precisos.

A resolução das imagens é uma grande parte se descobrir o quão bom é o *dataset*. Podem ser necessárias imagens de alta ou baixa resolução dependendo do foco da pesquisa ou projeto. Além disso, incluir recursos específicos, como cor, orientação e outras características visuais, é fundamental.

Esses recursos ajudam a criar um *dataset* mais abrangente e detalhado que pode ser utilizado para diversos fins. O desenvolvimento de um *dataset* de imagem requer uma consideração cuidadosa de seus requisitos e recursos de qualidade, o que garante que ele atenda ao propósito pretendido.

2. PREPARANDO RECURSOS PARA A EMPREITADA



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Como a importância do *dataset* de imagens continua a crescer em diferentes áreas de pesquisa, é essencial preparar recursos para dimensionar esses conjuntos de dados. Isso envolve entender as várias ferramentas e técnicas disponíveis para gerenciar e armazenar grandes quantidades de dados.

a) Gerenciamento: Os conjuntos de dados de imagens requerem gerenciamento adequado para garantir seu uso prático, seja para visão computacional, ML ou outras aplicações.


b) Preparação: Gerenciar e preparar dados de imagem requer uma consideração cuidadosa de fatores como **anotação, rotulagem e limpeza de dados**.

c) Armazenamento: Um aspecto crucial do processo de gerenciamento é selecionar os métodos de armazenamento mais adequados, como sistemas de arquivos distribuídos ou armazenamento em nuvem, que possam lidar com eficiência com o volume e a complexidade dos dados. O armazenamento em nuvem não apenas torna os dados mais fáceis de encontrar e acessar, mas também torna os dados mais seguros e confiáveis.

d) Segurança: Com o armazenamento em nuvem, os dados são criptografados e protegidos contra acesso não autorizado. Isso reduz o risco de violações de dados.

e) Ferramentas de Otimização: A escala de *dataset* de imagens requer uma compreensão abrangente das ferramentas e técnicas necessárias para otimizar o armazenamento, processamento e preparação de dados para análise.

As plataformas de armazenamento em nuvem oferecem soluções que podem ser ampliadas à medida que o armazenamento de dados cresce. Esforços colaborativos entre pesquisadores e partes interessadas também são possíveis, pois o armazenamento em nuvem permite fácil compartilhamento e colaboração em um ambiente seguro. À medida que o volume de conjuntos de dados de imagem aumenta, aproveitar o armazenamento em nuvem continua sendo crucial para gerenciar e armazenar arquivos grandes, mantendo a segurança e a acessibilidade dos dados.



3. ESTRATÉGIAS DE AQUISIÇÃO DE IMAGENS

A aquisição de imagens de alta qualidade é um passo essencial na construção de um *dataset* de imagens. Requer consideração cuidadosa de vários fatores, como fonte, formato e tamanho das imagens.

a) Fonte: A origem das imagens deve ser confiável para garantir autenticidade e credibilidade. Além disso, o formato deve ser compatível com o *dataset* e as ferramentas que serão utilizadas para análise.


Nota: Em post anterior (CARVALHO, 2024), foram publicados referências de *dataset* disponibilizados publicamente para diversas áreas do conhecimento humano. Podem ser um bom ponto de partida de construção de *dataset*.

b) Tamanho das Imagens: é outro fator crítico que deve ser considerado. Imagens grandes podem consumir recursos significativos de memória, enquanto imagens pequenas podem precisar fornecer mais detalhes para análise. Portanto, é necessário equilibrar a qualidade da imagem e o tamanho do arquivo. A seleção de imagens deve ser abrangente e representativa para garantir que o *dataset* represente com precisão a população ou os fenômenos pretendidos.

c) Aquisição de imagens: é um processo crítico que requer deliberação cuidadosa e atenção aos detalhes para garantir que o *dataset* seja preciso e confiável. O processo de aquisição deve incluir de forma abrangente as variações de ângulos, condições de iluminação e objetos.

Por fim, criar um *dataset* de imagens é crucial em muitos campos, como visão computacional e ML. Isso pode ser conseguido através da aquisição manual ou automatizada de imagens de diversas fontes, como bancos de dados *on-line*, repositórios, pesquisas estruturadas na web ou configurações personalizadas de câmeras.

É importante notar que a criação de um *dataset* de imagem não consiste apenas em coletar, mas também em garantir que eles sejam de alta qualidade, diversificados e



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

relevantes para a tarefa. Depois que o *dataset* de imagem é criado, ele pode ser usado para diversas aplicações, como reconhecimento de objetos, classificação de imagens e análise de cena. Concluindo, a criação de um *dataset* é fundamental para o avanço do campo da visão computacional e do ML.

4. PRÉ-PROCESSAMENTO E PREPARAÇÃO DE IMAGENS

Ao se trabalhar em um projeto com um conjunto de dados de imagens, é essencial configurar uma maneira confiável de lidar com os dados.

O pré-processamento e a preparação são etapas integrais para atingir esse objetivo. Essas etapas envolvem a **manipulação** e **otimização** das imagens para garantir que eles estejam em um formato que seja propício aos requisitos do projeto.


Durante a fase de pré-processamento, tarefas como **filtragem**, **redimensionamento** e **normalização** geralmente são feitas para garantir que todas tenham a mesma qualidade e formato. Esta etapa garante que os dados estejam prontos para análise, permitindo que os pesquisadores extraiam **insights** dos dados de forma mais eficaz.

O pré-processamento faz também com que os **modelos de ML** mais precisos, o que os torna melhores em tarefas como reconhecimento. Um bom pré-processamento é uma das etapas mais críticas para garantir que um projeto de conjunto de dados atenda aos seus objetivos e atenda a altos padrões de qualidade e precisão.

Além disso, é imperativo observar que o manuseio adequado de um *dataset* é crucial para seu uso bem-sucedido em aplicativos de ML e visão computacional. O **redimensionamento** e **recorte** durante a fase de preparação devem ser realizados com muito cuidado para garantir que os dados representem com precisão os objetos e cenas dos quais foram inicialmente retirados.

É importante ao usar o *dataset* para tarefas como detecção ou classificação de objetos, observar que a integridade do sistema afeta diretamente a precisão dos algoritmos. Para fazer um *dataset* confiável e útil, deve-se prestar muita atenção a cada detalhe durante a preparação.

5. VALIDAÇÃO E GARANTIA DA QUALIDADE



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

O *dataset* é crucial para muitos setores e campos de pesquisa, incluindo ML, visão computacional e IA.

a) Verificação: Para garantir dados da mais alta qualidade para processos de validação e garantia de qualidade, é crucial examinar minuciosamente e verificar a precisão de cada *dataset* antes de usar. Nesse processo, cada um é analisado, seus metadados são verificados e garante que atenda a padrões específicos. O *dataset* deve ser preciso e consistente para que os modelos de ML sejam confiáveis e robustos.

b) Testes de Qualidade e Validação: Dados de má qualidade podem levar a previsões imprecisas, o que pode ser prejudicial ao desempenho geral do sistema. Portanto, é essencial priorizar a qualidade dos dados ao trabalhar com conjuntos de dados para alcançar resultados precisos e confiáveis. Ao lidar com *dataset*, é crucial garantir que os dados dentro deles atendam aos padrões de qualidade esperados. Uma maneira de garantir isso é executando testes automatizados no conjunto de dados.

c) Identificação de Anomalias e Inconsistências: Isso ajuda a identificar quaisquer anomalias ou inconsistências nos dados, que podem então ser abordadas antes que se tornem problemas significativos. Recomenda-se também a realização de testes manuais para verificar a precisão de quaisquer detalhes adicionais incluídos no conjunto de dados, como rótulos ou anotações. Isso é especialmente importante para aplicações sensíveis ou essenciais, como imagens médicas ou carros autônomos. Aproveitar o tempo para testar e confirmar a precisão de um *dataset* pode economizar tempo e dinheiro no longo prazo e torná-lo mais confiável e confiável em geral.

d) Manutenção Periódica: É essencial verificar o conjunto de dados com frequência para garantir que sua precisão permaneça a mesma ao longo do tempo. Mudanças podem acontecer nos conjuntos de dados por vários motivos, como quando os dados são corrompidos ou surgem novas tecnologias. Testes de validação e garantia de qualidade devem ser feitos regularmente e quaisquer alterações necessárias devem ser feitas para manter resultados precisos. Além disso, recomenda-se estabelecer um protocolo para



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

manutenção e atualização regular de *dataset*. Essa prática garante que os usuários do *dataset* tenham acesso a dados confiáveis e atualizados.

Seguindo um processo de manutenção bem planejado, as organizações podem usar seus *datasets* como uma ferramenta confiável para obter *insights* e tomar decisões inteligentes. Em última análise, o sucesso de qualquer *dataset* depende do compromisso com a sua melhoria e manutenção contínuas.


6. PÓS-PROCESSAMENTO E FINALIZAÇÃO DO DATASET

Um *dataset* é uma coleção usada para diversos fins, incluindo treinamento de algoritmos de ML ou realização de pesquisas.

O pós-processamento do *dataset* é a etapa final e crucial na preparação do conjunto de dados para uso. Envolve um conjunto de etapas de garantia de qualidade que garantem a **correção, precisão e confiabilidade** dos dados.

O pós-processamento inclui várias técnicas, como **correção, normalização de dados, filtragem e segmentação**. Esses métodos garantem que sejam de alta qualidade, livres de ruído e mantenham o nível de consistência desejado. Por causa disso, o pós-processamento desempenha um papel significativo para garantir que o *dataset* esteja pronto para ser usado, confiável e útil no trabalho em direção à meta estabelecida para ele.

As tarefas de pós-processamento, como **rotulagem, categorização e criação de metadados** podem ser tediosas e demoradas, mas são fundamentais para tornar o *dataset* valioso para aplicativos de ML e visão computacional.





EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


Figura 2 – Validação do *Dataset* para IA.
Fonte: Adaptado de XOFFSHORINGT (2024).

O *dataset* é melhorado tanto em termos da sua qualidade como da sua confiabilidade após a eliminação do duplicado e a execução de verificações de qualidade. Os metadados fornecem informações essenciais sobre e contribuem para resultados de pesquisa mais precisos e úteis. O pós-processamento é uma etapa essencial na criação de um conjunto de dados preciso e valioso que pode ser usado em vários contextos e aplicações.

7. CONCLUSÃO

Criar um *dataset* em grande escala para os modelos de DL pode inicialmente parecer assustador. Ainda assim, se for empregada a estratégia apropriada, pode-se concluir a tarefa de forma rápida e eficiente. Se este guia for seguido, o resultado será um *dataset* que contribuirá para o desenvolvimento de modelos de ML confiáveis com mais frequência. Além disso, a ordem e a limpeza em relação a tudo e qualquer coisa associada à anotação e armazenamento estarão mantidos. Seguindo as diretrizes descritas neste guia pode-se construir um *dataset* que impulsionará significativamente os esforços de DL.

REFERÊNCIAS



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

XOFFSHORINGT, A Comprehensive Guide to Creating a Large-Scale Image Dataset for Deep Learning Models, Medium, 2024. Disponível em: <<https://medium.com/@24x7offshoringt/a-comprehensive-guide-to-creating-a-large-scale-image-dataset-for-deep-learning-models-e2922a9f36b1>>. Acessado em Ago 09, 2024.

24x7OFFSHORING. A Comprehensive Guide to Creating a Large-Scale Image Dataset for

Deep Learning Models? 2021. Disponível em: <https://24x7offshoring.com/a-comprehensive-guide-to-creating-a-large-image/?feed_id=32040&unique_id=65dff239aa281>. Acessado em Ago 09, 2024.

CARVALHO, A. Datasets de Acesso Livre para Projetos de IA!, Posts, EAILAB, IFSP, Jun 17, 2024. Disponível em: <https://eailab.labmax.org/2024/06/17/datasets-de-acesso-livre-para-projetos-de-ia/>. Acessado em Set 24, 2024.

Elaborado por: Dr. Arnaldo de Carvalho Junior

Publicado em: Set 24, 2024

Disponível em: <https://eailab.labmax.org/2024/09/24/roteiro-para-criacao-de-dataset-de-imagens-para-modelos-de-aprendizagem-profunda/>. Acessado em Nov 08, 2024.

**Post 11: Melhores bibliotecas Python para aprendizado de máquina****INTRODUÇÃO**

A inteligência artificial (IA) (*artificial intelligence* – AI) é um vasto campo da ciência da computação que está revolucionando indústrias e melhorando a vida das pessoas. Como apresentado em *post* anterior [1], o termo IA é amplo e aplicado ao desenvolvimento de sistemas e processos capazes de raciocinar, classificar, descobrir significado, generalizar ou aprender com experiências passadas. A IA engloba uma série de algoritmos, ferramentas matemáticas e estatísticas e pode ser subdividida em camadas, conforme a Figura 1 [2].




Figura 1 – Subdivisões da Inteligência artificial.

Fonte: Adaptado de [2].

O aprendizado de máquinas (*machine learning* – ML) é um subconjunto focado em sistemas capazes de aprender com os dados. Técnicas como aprendizado supervisionado, aprendizado sem supervisão e árvores de decisão são os pilares deste campo [1]. Já o aprendizado de máquinas pequeno (TinyML) é uma tecnologia que possibilita a execução de modelos de ML serem executados em dispositivos de baixo consumo, como sensores, dispositivos vestíveis (*wearables*) e dispositivos inteligentes para IA das coisas (*artificial intelligence of things* - AIoT), trazendo benefícios para empresas, como maior autonomia, privacidade e eficiência. Além disso permite um tempo



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

de resposta menor pois a tomada de decisão pode ser realizada na borda do sistema, onde o dispositivo está instalado, em vez de ter que consultar um sistema decisório na nuvem [3].

As redes neurais artificiais (RNA) (*artificial neural networks* - ANNs) são técnicas computacionais que apresentam um modelo matemático inspirado em cérebros biológicos e que adquirem conhecimento através da experiência [1].

O aprendizado profundo (*deep learning* – DL) é um ramo especializado de RNAs que se aprofunda em dados complexos. Tecnologias como redes neurais recorrentes – (*recurrent neural networks* – RNN) para séries temporais de dados, redes neurais convolucionais (*convolutional neural networks* – CNNs) para classificação de imagens e algoritmos transformadores (*transformer*) para processamento de linguagem natural são exemplos de DL [1],[4].

Uma linguagem de programação que tem se destacado em projetos de ML e TinyML é o Python. Entre as principais razões destacam-se a sintaxe clara e expressiva, tornando a linguagem fácil de aprender e usar, a flexibilidade e um poderoso ecossistema de bibliotecas e *frameworks*. Isso permite que os projetistas de IA possam se concentrar mais no desenvolvimento da aplicação e da solução do que na elaboração maçante de códigos e algoritmos [5]. A Figura 2 apresenta as principais bibliotecas utilizadas para TinyML e ML.





Figura 2 – Principais Bibliotecas para ML e TinyML.



Fonte: O autor (2025).

PRINCIPAIS BIBLIOTECAS PARA TINYML

a) Tensorflow: Desenvolvido pelo Google, o TensorFlow é uma poderosa estrutura de código aberto para criar e implantar modelos de ML. É particularmente popular para tarefas de aprendizado profundo e suporta ambientes de produção escaláveis.

Site: <https://www.tensorflow.org>

Código fonte: <https://github.com/tensorflow/tensorflow>

b) Keras: É uma interface de programação de aplicações (*application programming interface* - API) de redes neurais de alto nível que funciona perfeitamente com o TensorFlow. Ele simplifica a criação de modelos complexos de aprendizado de máquina, como RNNs, CNNs e Transformers, com uma interface amigável.

Site: <https://keras.io>

Código fonte: <https://github.com/keras-team/keras>

c) Numpy: É a espinha dorsal da computação científica em Python. O Numpy fornece suporte a grandes matrizes e matrizes multidimensionais, junto com uma coleção de funções matemáticas para operar nessas matrizes.

Site: <https://numpy.org>

Código fonte: <https://github.com/numpy/numpy>

d) Pandas: Simplifica a manipulação e análise de dados, facilitando a limpeza e o pré-processo de dados para tarefas de aprendizado de máquina.


Site: <https://pandas.pydata.org>

Código fonte: <https://github.com/pandas-dev/pandas>

e) Scikit-Learn: Biblioteca para o aprendizado de máquina, oferecendo ferramentas eficientes para pré-processamento, classificação, regressão, agrupamento e redução de dimensionalidade.

Site: <https://scikit-learn.org>

Código fonte: <https://github.com/scikit-learn/scikit-learn>



OUTRAS BIBLIOTECAS MUITO UTILIZADAS EM ML

Além das bibliotecas já citadas para TinyML, outras bibliotecas muito utilizadas em projetos de ML são:

a) Orange: É uma ferramenta de programação visual para visualização e análise de dados. É ideal para iniciantes no aprendizado de máquina, oferecendo uma interface interativa para criar modelos sem codificação extensa.

Site: <https://orange.biolab.si>

Código fonte: <https://github.com/biolab/orange3>

b) Matplotlib: Biblioteca fundamental para visualização de dados, o Matplotlib permite a criação de uma ampla gama de gráficos estáticos, animados e interativos para interpretar visualmente os conjuntos de dados.

Site: <https://matplotlib.org>

Código fonte: <https://github.com/matplotlib/matplotlib>

c) Seaborn: outra biblioteca Python de código aberto, baseado no Matplotlib, mas apresenta as estruturas de dados de Pandas. O SeaBorn é frequentemente usado em projetos de ML, pois pode gerar gráficos de dados de aprendizado. De todas as bibliotecas Python, produz os mais esteticamente agradáveis, tornando-o uma escolha eficaz se for utilizado também para marketing e análise de dados [6].

Site: <https://seaborn.pydata.org/>

Código fonte: <https://github.com/mwaskom/seaborn>

d) Pytorch: Mantida pela Meta (anteriormente Facebook), a Pytorch é conhecida por seu gráfico dinâmico de computação e facilidade de experimentação. É preferido na pesquisa e produção devido à sua flexibilidade e suporte nativo à aceleração da GPU.

Site: <https://pytorch.org>

Código fonte: <https://github.com/pytorch/pytorch>



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

e) **Scipy**: extensão do Numpy com funcionalidades adicionais para otimização, integração, interpolação e muito mais. É amplamente utilizado para tarefas científicas e de engenharia.

Site: <https://scipy.org>

Código fonte: <https://github.com/scipy/scipy>

PLATAFORMAS PARA ML E TINYML “NO-CODE”

Existem plataformas completas, que integram diferentes algoritmos e bibliotecas em uma *interface* amigável para o desenvolvimento de soluções de ML que podem ser embarcadas em praticamente qualquer *hardware*, inclusive dispositivos TinyML. Essas plataformas são chamadas de “sem código” (“*no-code*”) pois permitem que o processo de construção, implantação e escalabilidade de aplicativos ML possam ser incorporados de forma rápida e fácil, mesmo por leigos em programação de IA.

a) **Edge Impulse™**: é uma plataforma de operações de aprendizado de máquina (*machine learning operations* - MLOPS) baseada em nuvem para o desenvolvimento de sistemas ML incorporados e de borda (TinyML) que podem ser implantados em uma ampla gama de *hardwares* alvo [7]. O Edge Impulse é um exemplo de plataforma *no-code* que permite carregar diferentes bases de dados, selecionar o modelo de IA, treinar, avaliar e exportar para diferentes microcontroladores, como ESP32, Raspberry e Nvidia. A Figura 3 apresenta o fluxo de trabalho da plataforma.

Edge Impulse: <https://edgeimpulse.com/>




Figura 3 – Fluxo de trabalho da plataforma Edge Impulse.

Fonte: O autor (2025).



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


b) Edge AI Labs: representa uma nova plataforma que fornece uma coleção de conjuntos de dados, plantas e modelos de IA com curadoria de nossos grupos de trabalho e contribuição da comunidade da Edge AI Foundation, anteriormente conhecida como a fundação TinyML. A Edge AI Foundation é lugar da inovação global, colaboração, advocacia e educação. O Edge AI Labs fornece diversos modelos de ML para plataforma Raspberry..

Edge AI Labs: <https://edgeai.modelnova.ai/>

Edge AI Foundation: <https://www.edgeaifoundation.org/>

REFERÊNCIAS

- [1] CARVALHO JUNIOR, Arnaldo. Coletânea de Posts EAILAB 2023-2024. EAILAB, IFSP, 1º ed, 70p, 2024. Disponível em: <<https://github.com/EAILAB-IFSP/PUBLICATIONS/blob/main/POSTS%20EAILAB%20Vol%201%202024.pdf>>. Acessado em Jan 17, 2025.
- [2] DIACONU, Claudia *et al.* The Role of Artificial Intelligence in Monitoring Inflammatory Bowel Disease—The Future Is Now. *Diagnostics*, v. 13, n. 4, p. 735, 2023.
- [3] Objective. TinyML: O próximo passo da Inteligência Artificial e do Machine Learning, Objective, 2024. Disponível em: <<https://www.objective.com.br/insights/tinyml/>>. Acessado em Jan 17, 2025.
- [4] ZAEEM, Hayder. Best Python Libraries for Machine Learning, Python Developers Community (Linkedin Group), 2025. Disponível em: <https://media.licdn.com/dms/image/v2/D4E22AQHYQ44EAZ58rQ/feedshare-shrink_800/B4EZRk97wMG0Ag-/0/1736860746065?e=1740009600&v=beta&t=h1sDbbDMrwlI9SFPzUHHS_PEDNBZuwhtpHePjuoXmO0>. Acessado em Jan 17, 2025.
- [5] AWARI. Machine Learning com Python: Guia Completo e Exemplos. Awari Atividades de Ensino, 2024. Disponível em: <<https://awari.com.br/machine-learning-com-python-guia-completo-e-exemplos/>>. Acessado em Jan 17, 2025.




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[6] COURSERA STAFF, 9 Best Python Libraries for Machine Learning, Coursera, 2023. Disponível em: <<https://www.coursera.org/articles/python-machine-learning-library>>. Acessado em Jan 17, 2025.

[7] JANAPA REDDI, Vijay et al. Edge impulse: An mlops platform for tiny machine learning. Proceedings of Machine Learning and Systems, v. 5, 2023. Disponível em: <https://proceedings.mlsys.org/paper_files/paper/2023/file/49fe55f5e9574714dda575bfb2177662-Paper-mlsys2023.pdf>. Acessado em Jan 17, 2025.

**Post 12: Métricas de Desempenho em Modelos de IA (parte 1)****1. INTRODUÇÃO**


Medir o desempenho do modelo de Inteligência Artificial (IA) é fundamental para garantir que os sistemas de IA ofereçam resultados precisos, confiáveis e justos, e que se alinhem aos objetivos desejados [1]. Mas como se verifica o desempenho de um modelo de IA?

Medir o desempenho da IA requer uma abordagem estruturada, combinando os principais indicadores de desempenho (*key performance indicators* – KPIs) com conhecimentos técnicos para avaliar até que ponto os sistemas de IA se alinham com os objetivos desejados. Para isso existem métricas diretas, indiretas e éticas [2].

a) Métricas Diretas: ou métricas técnicas, avaliam a saída do modelo de IA comparando-o com a verdade fundamental. Essas métricas são essenciais para determinar a capacidade do modelo de fazer previsões precisas e para garantir alta qualidade do modelo [2].

b) Métricas Indiretas: não estão vinculadas diretamente à saída do modelo de IA, mas refletem como as capacidades de IA impactam objetivos de aplicação mais amplos. Exemplo: satisfação do usuário/cliente, redução de custos, aumento de receitas, eficiência operacional, etc [2].

c) Métricas Éticas: ou IA responsável, são um conjunto de métricas usadas para avaliar se um modelo de IA defende a justiça, está em conformidade com sistemas regulatórios, evita a discriminação e mantém a transparência em seu processo de tomada de decisão. A IA responsável é guiada por três princípios fundamentais: precisão, responsabilidade e transparência. Essas métricas ajudam as organizações a garantir que suas iniciativas de IA se alinhem com os regulamentos legais, as normas sociais e seus próprios valores de negócios. São especialmente críticas em modelos de aprendizado de máquina (*machine learning* – ML) de alto impacto, onde decisões injustas podem implicar perdas financeiras, de reputação ou problemas legais [2]. Consulte [3] para saber mais.



Neste *post* serão avaliados apenas as métricas diretas. É importante notar que nenhum modelo de IA está correto. Então, considerando-se as métricas diretas, melhor o modelo, melhor ele se ajusta aos dados. É tão simples quanto isso. Há muitas métricas diretas, como serão apresentados na continuidade deste *post*.

Nesta primeira parte serão avaliadas as métricas diretas para modelos de classificação, que usadas quando a variável de destino consiste em rótulos discretos. Exemplo: verdadeiro / falso, bom / ruim, classes A / B / C, etc [2]. Já na parte 2 serão avaliadas as métricas diretas para modelos de regressão.

2. MATRIZ DE CONFUSÃO


Para testar o desempenho de um modelo de classificação, uma matriz de confusão pode ser usada [1]. Em palavras simples, é uma matriz que compreende instâncias de eventos previstos e reais, conforme a Figura 1. O eixo horizontal indica o valor atual enquanto que o eixo vertical indica o previsto.

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

Figura 1 – Exemplo de Matriz de Confusão.
Fonte: Adaptado de [1].

Os quatro termos da Figura 1 são:

a) Verdadeiro Positivo (*true positive* – TP): Qualquer evento positivo que tenha sido corretamente previsto. Por exemplo: Passar em um exame (*positive event*) e foi previsto corretamente.



b) Verdadeiro Negativo (*true negative* – TN): Qualquer evento negativo que tenha sido corretamente previsto. Por exemplo: Não passar em um exame (*negative event*) e foi previsto corretamente como falho (*failed*).

c) Falso Positivo (*false positive* – FP): Qualquer evento negativo que tenha sido previsto positivo. Por exemplo: O paciente não está tendo nenhuma doença. Mas os resultados do teste disseram (previsto) a pessoa está infectada. Isto pode ter os efeitos nocivos de “ser submetido desnecessariamente a tratamento médico indesejado”.

d) Falso Negativo (*false negative* – FN): Qualquer evento positivo que tenha sido previsto como negativo. Por exemplo: Há uma ameaça a um local público e a equipe de inteligência não consegue identificá-lo, ou seja, denunciá-lo como não uma ameaça. Isso pode ser um problema sério.


3. MÉTRICAS PARA MODELOS DE CLASSIFICAÇÃO

São usadas quando a variável de destino consiste em rótulos discretos. Exemplo: verdadeiro / falso, bom / ruim, classes A / B / C, etc [2]. Os principais tipos são:

a) Precisão: Mede a proporção de previsões positivas que estavam realmente corretas. É a proporção entre positivos verdadeiros (TP) e casos previstos como positivos. Útil quando o custo dos falsos positivos (FP) é alto (e, por exemplo, diagnóstico da doença). É dada pela Equação (1) a seguir:

$$\frac{TP}{TP + FP} \quad (1)$$

b) Recall: Mede a proporção de positivos reais que foram corretamente identificados. Importante ao perder um verdadeiro positivo é caro (exemplo: detecção de fraude). O *recall* mede a quantidade de vezes que o modelo de IA acerta em relação ao total de vezes que ele deveria ter acertado. É dada pela Equação (2) a seguir:



$$\frac{TP}{TP + FN}$$

(2)

O *Recall* é também chamado de **Sensibilidade** (*Sensitivity*) ou Taxa de Positivos Verdadeiros (*True Positive Rate* – TPR). Indica a proporção entre eventos positivos corretamente previstos para o total de eventos positivos.

O numerador, TP, representa o número de verdadeiros positivos (true positive), enquanto o denominador (TP + FN) (true positive + false negative) representa o número total de casos positivos reais no conjunto de dados. Ao dividir o número de verdadeiros positivos pela soma de verdadeiros positivos e falsos negativos, obtemos o valor da sensibilidade [1].


Na Ciência, Sensibilidade é a capacidade de identificar corretamente casos positivos. A Sensibilidade, também chamada de taxa positiva ou recordação positiva, é uma medição estatística que determina a proporção de casos positivos reais corretamente identificados por um modelo de aprendizado de máquina. Em outras palavras, a Sensibilidade quantifica a capacidade do modelo de detectar corretamente as instâncias positivas dentro de um conjunto de dados [1].

A **Sensibilidade** é uma métrica crítica no ML, pois reflete a capacidade do modelo de detectar corretamente instâncias positivas dentro de um conjunto de dados. É especialmente importante em aplicações em que a identificação de casos positivos verdadeiros é de extrema importância, como diagnóstico médico, detecção de fraude ou detecção de anomalia [1],[4].

c) Taxa negativa verdadeira (true negative rate – TNR): Também chamada de **Especificidade** (*Specificity*), indica com que frequência o modelo previu os eventos negativos corretamente. Ela avalia a capacidade do modelo de identificar corretamente a ausência da variável de destino em um conjunto de dados. Pode ser calculada como a relação de eventos negativos corretamente previstos (true negative – TN) corretamente e o total de eventos negativos [1]. A Especificidade é dada pela Equação (3) a seguir:

$$\frac{TN}{TN + FP}$$

(3)



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Para entender a Especificidade, é necessário entender o conceito de verdadeiros negativos (TN) e falsos positivos (false positive – FP). Os verdadeiros negativos representam os casos em que o modelo de IA classifica corretamente as instâncias como negativas, enquanto falsos positivos ocorrem quando o modelo identifica incorretamente os casos negativos como positivos [1],[4].

O numerador, TN, representa o número de negativos verdadeiros, enquanto o denominador (TN + FP) representa o número total de casos negativos reais no conjunto de dados. Ao dividir o número de negativos verdadeiros pela soma de verdadeiros negativos e falsos positivos, obtêm-se o valor da Especificidade [4].

A **Especificidade** é particularmente valiosa em cenários em que a identificação correta de casos negativos é crítica. Por exemplo, em exames médicos, a Especificidade mede a capacidade do modelo de identificar corretamente indivíduos sem uma doença ou condição específica. Um alto valor de Especificidade implica que o modelo pode efetivamente filtrar indivíduos que são verdadeiramente negativos, reduzindo as chances de falsos positivos e minimizando intervenções ou tratamentos desnecessários [4].

d) Taxa de Falsos Positivos (FPR): Porcentagem de instâncias negativas classificadas incorretamente como positivas. Pode ser descrita como: $FPR = 1 - \text{Especificidade}$. Indica com que frequência o modelo classificou os eventos negativos como positivos. A proporção de eventos positivos denominados incorretamente em relação ao total de eventos negativos. Útil para compreender riscos potenciais, especialmente em sistemas de IA implantados em domínios sensíveis como finanças ou saúde [4]. A FPR é dada pela equação (4) a seguir:

$$\frac{FP}{TN + FP} \quad (4)$$

e) Acurácia (Accuracy): mede a frequência de vezes em que o modelo previu corretamente. A proporção dos casos verdadeiros para todos os casos. É dada pela Equação (5) a seguir:

$$\frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$



f) Pontuação F1 (*F1 Score*): Média harmônica que combina **precisão** e **recall**, equilibrando a troca entre falsos positivos e falsos negativos. É dada pela Equação (6) a seguir:

$$F1\ Score = \frac{TP}{TP + \frac{1}{2}(FP + FN)} \quad (6)$$

Nota: Sensibilidade refere-se a quanto bom todos os eventos positivos atuais estão em previstos eventos positivos.

g) ROC e AUC: Deve haver um limite, um valor de limiar, que ajuda o modelo de IA a classificar. A curva característica do operador receptor (*receiver operator characteristic curve* - ROC) ajuda a decidir o melhor valor limite.

A curva ROC é basicamente um gráfico traçado entre a taxa de verdadeiros positivos (TP) e a taxa de falsos positivos (FP). Portanto, é um gráfico entre a **frequência** com que um modelo prevê eventos positivos como positivos e a frequência com que um modelo prevê eventos negativos como positivos [2].


A Área sob a curva (*area under curve* – AUC) é uma das métricas amplamente usadas e basicamente usada para **classificação binária**. A AUC de um classificador é definida como a probabilidade de um modelo classificar (*rank*) um exemplo positivo escolhido aleatoriamente maior que um exemplo negativo [2].

4. APLICAÇÕES

Exemplo 1: Suponha que um modelo de IA classificou 100 tumores como maligno (a classe positiva) ou benigno (a classe negativa):

a) Verdadeiro Positivo (TP): Realidade – maligno, modelo de ML previsto – maligno. Número de resultados TP igual a 1.

b) Falso Positivo (FP): Realidade – benigno, modelo de ML previsto – maligno. Número de resultados FP igual a 1.



c) Falso Negativo (FN): Realidade – maligno, modelo de ML previsto – benigno. Número de resultados FN igual a 8.

d) Verdadeiro Negativo (TN): Realidade – benigno, modelo de ML previsto – benigno. Número de resultados TN igual a 90.

Aplicando-se as Equações (1) a (6), tem-se:

$$\text{Precisão} = \frac{TP}{TP+FP} = \frac{1}{1+1} = 0.5$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{1}{1+8} = 0.11$$

$$\text{TNR} = \frac{TN}{TN+FP} = \frac{90}{90+1} = 0.99$$

$$\text{FPR} = \frac{FP}{TN+FP} = \frac{1}{90+1} = 0.01$$

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{1+90}{1+90+1+8} = 0.91$$

$$\text{F1 Score} = \frac{TP}{TP+0.5(FP+FN)} = \frac{1}{1+0.5(1+8)} = 0.18$$

A Figura 2 apresenta a curva ROC para este exemplo [1]. O modelo ao longo da linha tracejada seria o pior classificador. Não se pode discriminar entre as classes. A AUC seria 0.5 neste caso. O modelo ao longo da linha verde paralela ao eixo x na parte superior é o melhor modelo. A AUC seria 1. Classifica perfeitamente os eventos positivos e negativos. Qualquer modelo ou curva (*curve*) entre estes dois terá uma área maior que 0.5 e menor que 1. Isto resulta na sobreposição de classes e, portanto, são introduzidos erros do Tipo 1 e do Tipo 2.




Figura 2 – Curva ROC do Exemplo 1 do post anterior [1].
Fonte: Adaptado de [2].

Para diferentes limiares, é calculada a Sensibilidade e o FPR (1- Especificidade). FP baixo significa negativos verdadeiros mais altos. Uma curva é traçada. Dependendo de quantos Falsos Positivos aceitar, o limite é selecionado.

Para comparar modelos, aquele com AUC maior oferece o melhor. Na Figura 2, o modelo da curva vermelha é melhor que o da linha azul. Em alguns casos, por exemplo, quando se tem muitos casos negativos, pode-se optar pela **Precisão** em caso de Falso Positivo. Para isso o pesquisador deve saber qual é o seu objetivo primeiro.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Exemplo 2: A Figura 3 apresenta 6 imagens com a respectiva classificação [5].

Animal		Barn owl
		Chihuahua
		Sheep dog
Not animal		Apple
		Muffin
		Mop

Figura 3 – Animais e Coisas que se parecem com animais.

Fonte: Adaptado de [5].

A Figura 4 apresenta a matriz de confusão com classificações perfeitas e imperfeitas.

		Predicted			
		Animal	Not animal		
Actual	Animal	  		True Positives	3
	Not animal		  	True Negatives	3
				False Positives	0
				False Negatives	0

(a)

		Predicted			
		Animal	Not animal		
Actual	Animal	 		True Positives	2
	Not animal		 	True Negatives	2
				False Positives	1
				False Negatives	1

(b)

Figura 4 – Matriz de confusão com predições perfeitas (a) e imperfeitas (b).

Fonte: Adaptado de [5].

A Figura 5 apresenta a situação em que um modelo classifica todas as figuras como “Animal”.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo




Figura 5 – Modelo com classificação de todas as imagens como “Animal”.

Fonte: Adaptado de [5].

A Figura 6 apresenta a situação em que um modelo de IA classifica todas as imagens como “Não Animal (Not Animal)”.




Figura 6 – Modelo com classificação de todas as imagens como “Not Animal”.

Fonte: Adaptado de [5].



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

A Figura 7 apresenta uma situação em que há mais previsões como “Not Animal” e menos como “Animal”. Já a Figura 8 apresenta o exemplo oposto, com mais previsões classificadas como “Animal” do que como “Not Animal”.




Figura 7 – Modelo de IA com mais classificações do tipo “Not Animal” do que “Animal”.

Fonte: Adaptado de [5].





Figura 8 – Modelo de IA com mais classificações como “Animal” do que como “Not Animal”.

Fonte: Adaptado de [5].

5. CONCLUSÃO



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Em resumo:

- a) Sensibilidade refere-se a quanto bom todos os eventos positivos atuais estão em previstos eventos positivos.
- b) Precisão refere-se quanto todos os eventos positivamente previstos foram corretamente previstos.
- c) Acurácia é o quão corretamente todos os eventos foram previstos.
- d) Especificidade é o quão bom está a previsão de eventos negativos.


Como saber qual deles procurar?

Se o pesquisador está mais interessado em casos de Falso Positivo, deve optar pela **Precisão**. Se os casos Falsos Negativos são o que o pesquisador procura, então **Recall** é uma boa medida. A **Acurácia** é melhor se houver um cenário tendencioso. Se for imparcial — Precisão e *Recall*. O F1 Score ajuda se o pesquisador está incomodado com ambos os valores. É uma média harmônica, ou seja, uma média ponderada de Precisão e Recall.

A **sensibilidade** é uma métrica valiosa para avaliar a capacidade de um modelo de aprendizado de máquina de identificar corretamente **casos positivos**. Um alto valor de sensibilidade sugere uma forte capacidade de capturar instâncias positivas, enquanto um baixo valor de sensibilidade indica uma maior probabilidade de falta de casos positivos. A interpretação da sensibilidade resulta no contexto dos requisitos do aplicativo e em conjunto com outras métricas de desempenho ajuda a determinar a eficácia e a adequação do modelo. A **especificidade** é uma métrica fundamental no aprendizado de máquina que mede a capacidade do modelo de identificar corretamente **casos negativos**. Ela desempenha um papel crucial na avaliação do desempenho do modelo e sua adequação a aplicações específicas, onde é essencial identificação precisa de instâncias negativas.

6. REFERÊNCIAS

- [1] KAKANADAN, U. Regression and performance metrics — Accuracy, precision, RMSE and what not!, Medium, 2024. Disponível em: <<https://medium.com/analytics-vidhya/regression-and-performance-metrics-accuracy-precision-rmse-and-what-not-223348cfcafe>>. Acessado em Jul 31, 2024.
- [2] DILMEGANI, C. How To Measure AI Performance, AI Multiple Research, 2025. Disponível em: <[how-to-measure-ai-performance](#)>. Acessado em Mai 05, 2025.




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[3] WRIGHT, S. A.; SCHULTZ, A. E. The rising tide of artificial intelligence and business automation: Developing an ethical framework. **Business Horizons**, v. 61, n. 6, p. 823-832, 2018. DOI: 10.1016/j.bushor.2018.07.001.

[4] STITH, L. What is Sensitivity and Specificity in Machine Learning. Robots.Net, Nov 2023. Disponível em: <<https://robots.net/fintech/what-is-sensitivity-and-specificity-in-machine-learning>>. Acessado em Ago 01, 2024.

[5] TIGERSCHIOLD, T. What is Accuracy, Precision, Recall and F1 Score?, Labelf, 2022. Disponível em: <<https://www.labelf.ai/blog/what-is-accuracy-precision-recall-and-f1-score>>. Acessado em Nov 13, 2024.

**Post 13: Métricas de Desempenho em Modelos de IA (parte 2)****1. INTRODUÇÃO**

Este *post* continua a tratar métricas de desempenho iniciadas no post anterior [1], onde foram abordadas as métricas de desempenho de modelos de IA para classificação.

Neste *post* serão abordadas as métricas de desempenho de regressão, utilizadas em modelos de IA para aproximação de funções, identificação de sistemas, previsões, entre outras aplicações [2].

Primeiro, segue uma introdução da Regressão Linear/Múltipla Linear.

1.1. Regressão Linear / Múltipla

A Regressão é uma técnica cujo objetivo é prever o valor de uma variável dependente (Y) quando se tem um conjunto de valores que são as variáveis independentes (X). A Regressão Linear é uma das técnicas mais básicas em aprendizado de máquinas (*machine learning* - ML) que se pode utilizar para realizar previsões [3][4].


Uma Equação de Regressão é dada em (1), onde 'E' significa o erro que é introduzido quando o modelo realmente não se encaixa nos dados. O objetivo de um bom modelo de regressão é minimizar esse erro.

$$y = B_0 + B_1x_1 + B_2x_2 + E \tag{1}$$

O erro é dado pela diferença entre o valor real (y) e o valor predito ($\hat{y}$) pelo modelo.

2. MÉTRICAS DE REGRESSÃO

Usadas quando a variável alvo é contínua [5]. Exemplo: preços de casas, previsão de temperatura, valores de estoque, etc. A seguir são apresentadas métricas utilizadas para avaliar modelos de regressão:



a) Raiz do erro quadrático médio (*root mean square error* - **RMSE):** Mede a raiz quadrada das diferenças quadráticas médias entre os valores previstos e reais. Penaliza fortemente grandes erros, tornando-o ideal para modelos onde grandes desvios são críticos.

b) Erro quadrado (*square error* - **SE):** A diferença quadrada bruta entre os valores previstos e reais. Útil para enfatizar erros atípicos.

c) Erro Absoluto Médio (*mean absolute error* - **MAE):** Mede as diferenças absolutas médias entre os valores previstos e reais. Mais fácil de interpretar e menos sensível a outliers em comparação com RMSE.

Essas métricas ajudam a quantificar o desempenho do sistema e orientam a melhoria contínua durante o desenvolvimento e implantação do modelo de IA [5].


A seguir são apresentadas métricas utilizadas para avaliar modelos de regressão, tais como MAE, MAPE, MSE, RMSE, R^2 e R^2 ajustado.

2.1 MAE

O erro médio absoluto (MAE) pode ser calculado conforme a Equação (2). Nesta equação há o cálculo da média da diferença entre o valor predito $\hat{y}$ e o real y . Quanto menor o valor de MAE, significa que melhor são os resultados preditos pelo modelo de ML [6][7].

$$MAE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

O valor de saída da equação tem a mesma escala dos dados utilizados para previsão, tornando mais fácil a sua interpretação. Se o valor de **MAE** resultante for igual a 10,05 m, por exemplo, este resultado significa que o modelo pode estar errando em média 10,05 m para mais quanto para menos (erro de $\pm 10,05$ m) em relação ao valor correto. Por esta razão que este resultado precisa ser levado em consideração para a tomada de decisão quando analisando previsão futura [6].



Mas o quanto este erro representa em relação ao valor real percentualmente?

2.2. MAPE

O erro percentual absoluto médio (*mean absolute percentual error* - MAPE) é uma métrica que mostra a porcentagem de erro em relação aos valores reais. A Equação (3) apresenta o cálculo de MAPE que é semelhante ao MAE, mas com o acréscimo de uma divisão por $|y|$. Então se o resultado do MAPE for igual a 35% significa que o modelo de IA faz previsões que em média a diferença entre o valor previsto e o real equivale a $\pm 35\%$ do valor real [6].

$$MAPE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{\max(\epsilon, |y_i|)} \quad (3)$$


Ao observar a Equação (3) nota-se que caso o valor de y seja 0, ocorrerá um erro, devido a divisão por zero. Por isso que a biblioteca [scikit-learn](https://scikit-learn.org/) utiliza a tratativa de colocar um número muito pequeno, representado por ϵ , cujo valor é $2,220446049250313e-16$. A métrica MAPE é uma das métricas mais usadas para reportar a performance do modelo de IA, oferecendo uma compreensão mais abrangente do resultado do MAE.

2.3. MSE

O erro quadrático médio (*mean square error* – MSE) nada mais é do que a média dos quadrados da diferença entre os valores observados e previstos. Ele é dado pela Equação (4).

$$MSE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4)$$

Onde n é o número de termos, y_i significa o valor observado para o i -ésimo termo e $\hat{y}_i$ refere-se ao valor previsto para esse termo específico. A diferença é o termo **Erro**. Soma-



se os quadrados de todos os termos de erro e divide-se pelo grau de liberdade (número de variáveis independentes, ou n).

Mas por que ao quadrado? Para que o erro seja acumulado em vez de erros negativos cancelarem erros positivos.

A métrica MSE apresenta um problema de interpretabilidade. Por haver a elevação ao quadrado, a unidade fica distorcida, em outras palavras, se a unidade medida for metros (m), o resultado será em m^2 . Por isso que uma adaptação da MSE é a RMSE que será apresentada a seguir.

2.4. RMSE

RMSE é a raiz do MSE, conforme a Equação (5). O RMSE é basicamente o mesmo cálculo de MSE, contendo ainda a mesma ideia de penalização entre diferenças grandes do valor previsto e o real. No entanto, para lidar com o problema da diferença entre unidades, é aplicada a raiz quadrática. Assim a unidade fica na mesma escala que o dado original, sendo o resultado da métrica melhor interpretável [6].

$$RMSE(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5)$$

Nesta equação há o cálculo da diferença entre o valor y e $\hat{y}$, contudo com a elevação do resultado ao quadrado. Mas para deixar o resultado na mesma escala que os dados, é aplicado a raiz quadrada no resultado. Apesar de o valor ter a mesma unidade, ele não costuma se assemelhar ao resultado encontrado de MAE, demonstrando como os *outliers* podem estar impactando nas previsões do modelo. Mas a sua interpretabilidade pode seguir a mesma lógica, onde o resultado da métrica sendo igual a 70,0 m, significa que o modelo pode estar errando em $\pm 70,0$ m. Por essa razão, esta métrica pode ser uma boa opção quando é preciso ter uma avaliação mais criteriosa sobre as previsões do modelo.

2.5. R^2



O R-quadrado, R-dois ou coeficiente de determinação, é uma medida estatística de quão próximos os dados estão da linha de regressão ajustada. Ele também é conhecido como o coeficiente de determinação ou o coeficiente de determinação múltipla para a regressão múltipla. A definição do R^2 é bastante simples: é a porcentagem da variação da variável resposta que é explicada por um modelo linear [5]. Ou:

$R^2 = \text{Variação explicada} / \text{Variação total}$ (Equação (6))

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6)$$

Os valores de y são os valores verdadeiros e o $\bar{y}$ é a média desses valores, enquanto que $\hat{y}$ são os valores preditos. Os resultados de R^2 ficam entre 0 e 1, quanto mais perto de 1 melhor e pior para resultados perto de 0. O R^2 está sempre entre 0 e 100%:

- a) 0% indica que o modelo não explica nada da variabilidade dos dados de resposta ao redor de sua média.
- b) 100% indica que o modelo explica toda a variabilidade dos dados de resposta ao redor de sua média.


Em geral, quanto maior o R^2 , melhor o modelo se ajusta aos seus dados. No entanto, existem condições importantes para esta diretriz.

A proporção de variância na variável dependente que é prevista a partir das variáveis independentes. O valor varia de 0 a 1. 1 mostra que a regressão explica perfeitamente a relação. 0 o oposto.

Se A proporção de variância na variável dependente que é prevista a partir das variáveis independentes. O valor varia de 0 a 1. 1 mostra que a regressão explica perfeitamente a relação. 0 o oposto.

Se R^2 (Leia como *R-quadrado*)= 0,45 para a equação (1) de regressão do item 1.2, então significa que 45% da variabilidade em y é explicado pelas variáveis x_1 e x_2 .

No entanto há uma falha. À medida que o número de termos aumenta, o R^2 pode permanecer constante ou aumentar. Isso acontece mesmo que não haja uma boa relação entre as variáveis e a variável dependente [5]. Assim sendo, utilizando somente a métrica



R^2 , será que um valor de 0,5 já seria o suficiente para colocar o modelo em produção? Faz-se necessário aproximar ainda mais o seu resultado para 1? Para responder a essas questões, recomenda-se sempre utilizar outras métricas para uma análise mais completa sobre a performance do modelo de IA [6].

Depois de elevá-lo ao quadrado, é necessário reduzir a escala para as unidades originais.

2.4. R^2 Ajustado


R^2 Ajustado é um refinamento sofisticado da métrica R^2 convencional, sendo uma ferramenta poderosa no escopo da avaliação de modelos. À medida que novos preditores são introduzidos, o R^2 Ajustado adapta-se dinamicamente, ascendente ou descendente, com base na medida em que estes preditores melhoram o desempenho do modelo. Este ajuste perspicaz transcende as limitações do R^2 convencional, que captura apenas a proporção de variância explicada pela variável independente(s). Um valor ajustado que considerará a relação entre as variáveis. Diminuirá o valor para variáveis que não melhoram o modelo existente. A fórmula para o R^2 ajustado é dada pela Equação (7) [8].

$$\text{Adjusted } R^2 = 1 - \frac{(1 - R^2)(N - 1)}{N - p - 1} \quad (7)$$

Onde N é dado pelo número de registros em um *dataset* e p o número de variáveis independentes.

Em total contraste com o R^2 convencional, que permanece indiferente ao número de preditores utilizados, o R^2 ajustado aparece como um avaliador perspicaz e sensato, penalizando profundamente a inclusão de características irrelevantes ou redundantes que não têm impacto significativo na previsão da variável alvo. Esta métrica astuta considera cuidadosamente a contagem de variáveis independentes implementadas no processo de previsão, abrindo caminho para uma avaliação mais abrangente e equitativa das proezas preditivas do modelo.

Ao ajustar seu valor com base no número de preditores, o R^2 ajustado eleva o processo de avaliação do modelo para um escalão superior, orientar os pesquisadores para a seleção dos preditores mais influentes e pertinentes, ao mesmo tempo que desencoraja a



incorporação de variáveis supérfluas. Este ajuste refinado equipa os cientistas de dados com uma ferramenta poderosa e informada, mantendo a curadoria de modelos mais parcimoniosos que atingem um equilíbrio ideal entre precisão preditiva e parcimônia.

De tudo isso, deve ter tido agora alguma ideia sobre como os modelos podem ser comparados em uma regressão.

3. RESUMO

A Tabela 1 a seguir aponta as principais diferenças entre as métricas de avaliação de regressão MSE, RMSE, MAE, MAPE, R^2 e R^2 ajustado [9].

Tabela 1
Comparação entre Métricas de Regressão MSE, RMSE, MAE, MAPE, R^2 e R^2 ajustado [9]

Métricas	O que?	Por quê?	Quando Usar?
MSE	Mede a diferença quadrática média entre os valores estimados e reais.	Enfatiza erros maiores.	Quando erros grandes são mais críticos.
RMSE	Raiz quadrada do MSE, nas mesmas unidades da variável resposta.	Interpretação mais fácil dos erros.	Quando a escala de erro deve corresponder à escala alvo.
MAE	Diferença absoluta média entre os valores estimados e reais.	Menos sensível a outliers.	Com muitos valores discrepantes ou resíduos não normais.
MAPE	Erro percentual entre valores estimados e reais.	Fácil interpretação como porcentagem.	Para previsão e análise de erros baseada em porcentagem.
R^2	Proporção de variância explicada pelo modelo.	Indica o poder explicativo do modelo.	Avaliar modelos de regressão linear fit.
R^2 Ajustado	Medida estatística que modifica o valor R^2 para contabilizar o número de preditores	Ao contrário do R^2 , penaliza o modelo por incluir preditores irrelevantes	Útil em cenários de regressão múltipla onde você tem várias variáveis independentes

4. CONCLUSÃO

Neste *post* foram apresentadas algumas das métricas mais utilizadas para avaliar o modelos de regressão acompanhado de suas particularidades.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo


Como visto a métrica a ser adotada depende da solução que o modelo pode vir a resolver com o modelo de ML. Uma abordagem comum, fácil de ser implementada e muito interessante é utilizar todas para se ter diferentes perspectivas em relação a performance do modelo.

Dentre as métricas apresentadas, o R^2 é uma métrica muito comum, mas difícil de ser utilizada sozinha para se tirar conclusões completas sobre a performance do modelo. O R^2 ajustado é um resultado muito importante para saber se o conjunto de dados é adequado ou não. Alguém faz uma equação de regressão para validar se o que pensa sobre a relação entre duas variáveis é também validado pela equação de regressão. Quanto maior for o R^2 ajustado, melhor é a equação de regressão, uma vez que implica que a variável independente escolhida para determinar a variável dependente seja corretamente escolhida. Idealmente, um investigador procurará o coeficiente de determinação mais próximo dos 100%.

Tanto MAE e MAPE apresentam uma boa interpretabilidade, principalmente para relatório dos resultados do modelo. Já as métricas MSE e RMSE são afetadas por valores discrepantes, o que pode ser importante quando é preciso ter uma avaliação mais criteriosa do modelo de ML.

5. REFERÊNCIAS

- [1] CARVALHO JUNIOR, A. Métricas de Desempenho em Modelos de IA (parte 1), EAILAB, IFSP, 2025. Disponível em: [https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%2012%20-%20Métricas%20de%20Desempenho%20em%20Modelos%20de%20IA%20\(parte%201\).pdf](https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%2012%20-%20Métricas%20de%20Desempenho%20em%20Modelos%20de%20IA%20(parte%201).pdf). Acessado em Mai 10, 2025.
- [2] CARVALHO, A., JUSTO, J.F., ANGÉLICO B.A. et al. Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946, DOI: [10.1016/j.asoc.2022.109927](https://doi.org/10.1016/j.asoc.2022.109927).
- [3] KAKANADAN, U. Regression and performance metrics — Accuracy, precision, RMSE and what not!, Medium, 2024. Disponível em: <https://medium.com/analytics-vidhya/regression-and-performance-metrics-accuracy-precision-rmse-and-what-not-223348cfcafe>. Acessado em Jul 31, 2024.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[4] AMORIM, N. Regressão Linear Simples com Python e sklearn, Dev 4.0, 2021. Disponível em:

<https://dev4lab.github.io/posts/regressao-lienar-com-python/#:~:text=Regressão%20Linear%20%C3%A9%20uma%20das%20t%C3%A9cnicas>. Acesso em Mai 12, 2025.

[5] DILMEGANI, C. How To Measure AI Performance, AI Multiple Research, 2025. Disponível em: <https://research.aimultiple.com/how-to-measure-ai-performance/>. Acessado em Mai 05, 2025.

[6] MINITAB, Análise de regressão: Como interpretar o R-quadrado e avaliar a qualidade de ajuste? Blog do Editor, Minitab, 2019. Disponível em: <https://blog.minitab.com/pt/analise-de-regressao-como-interpretar-o-r-quadrado-e-avaliar-a-qualidade-de-ajuste>. Acessado em Mai 06, 2025.

[7] OLIVEIRA JUNIOR, C. Métricas para Regressão: Entendendo as métricas R^2 , MAE, MAPE, MSE e RMSE, Medium, 2021. Disponível em: <https://medium.com/data-hackers/prevendo-números-entendendo-métricas-de-regressão-35545e011e70>. Acesso em Mai 12, 2025.

[8] RAJESH, P. S. What is Adjusted R-Squared, Net-Information.com, 2024. Disponível em: <https://net-informations.com/ds/psa/adjusted.htm>. Acesso em Mai 13, 2025.

[9] KUMAR, A. MSE vs RMSE vs MAE vs MAPE vs R-Squared: When to use?, Analytics logue, 2024. Disponível em: <https://vitalflux.com/mse-vs-rmse-vs-mae-vs-mape-vs-r-squared-when-to-use/>. Acesso em Mai 13, 2025.

**Post 14: Evolução da IA Tradicional para a IA Generativa e Agencial****1. IA EVOLUÇÃO DA IA**


A Inteligência Artificial (IA) passou, nos últimos anos, por uma transformação profunda — não apenas em termos de desempenho, mas principalmente de paradigma. Essa evolução pode ser compreendida em três grandes etapas: IA Tradicional, IA Generativa e IA Agêntica (ou Agencial), conforme Figura 1.



Figura 1: Evolução da IA.

IA Tradicional: A IA tradicional é baseada em modelos especializados, treinados para tarefas específicas, como classificação, regressão, detecção de padrões e otimização. Nessa fase, predominam algoritmos de aprendizado de máquinas (*Machine Learning* - ML) supervisionado, não supervisionado e métodos simbólicos. Esses sistemas são eficazes, porém reativos, dependentes de dados bem definidos e com pouca ou nenhuma autonomia. Eles executam o que foi programado ou aprendido, mas não “tomam iniciativa”.

IA Generativa (IAG): Com o avanço do aprendizado profundo (*Deep Learning* – DL) e, em especial, dos modelos de linguagem de grande escala (*Large Language Models* – LLMs), surge a IA generativa. Essa nova geração de IA não apenas reconhece padrões,



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

mas cria conteúdo: textos, códigos, imagens, áudios e vídeos. A IA generativa amplia drasticamente a capacidade de interação homem-máquina, tornando a IA mais acessível e versátil. Entretanto, apesar de sofisticada, ela ainda é majoritariamente reativa, respondendo a comandos sem autonomia real ou compreensão de objetivos de longo prazo.

IA Agêntica (ou IA Agencial): A etapa mais recente dessa evolução é a IA agêntica. Aqui, a IA deixa de ser apenas um modelo ou um gerador de conteúdo e passa a atuar como um **agente autônomo orientado a objetivos**. Sistemas agênticos combinam LLMs, geração aumentada por recuperação de conhecimento (*Retrieval-Augmented Generation* – RAG), memória de longo prazo, planejamento, uso de ferramentas e, frequentemente, arquiteturas multiagente. O IA Agencial é capaz de perceber, decidir, agir, aprender e colaborar, aproximando-se de uma inteligência operacional contínua.

Em síntese, a trajetória da IA pode ser vista como uma progressão:

- da execução de tarefas específicas (IA Tradicional),
- para a geração de conteúdo inteligente (IA Generativa),
- até a autonomia orientada a objetivos (IA Agêntica).


Essa evolução não substitui os paradigmas anteriores, mas os incorpora e expande, abrindo caminho para aplicações mais robustas, adaptativas e alinhadas a contextos complexos do mundo real.

2. LLM, RAG, AGENTES DE IA

LLM: é um modelo de inteligência artificial treinado com grandes volumes de texto para entender e gerar linguagem natural. Ele aprende padrões estatísticos da língua — como palavras, frases e contextos — e, a partir disso, consegue responder perguntas, escrever textos, resumir informações e até gerar código. Embora pareça “entender” o que diz, o LLM não possui consciência ou intenção própria: ele apenas prediz a próxima palavra mais provável com base no contexto fornecido e no conhecimento aprendido durante o treinamento.

Em síntese, o LLM é:

- Geração de linguagem



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- Modelo estatístico treinado
- Sem memória externa
- Reativo

RAG: é uma arquitetura de IA que combina recuperação de informação com geração de texto por modelos de linguagem, permitindo que o agente responda com base em conhecimento externo atualizado e verificável, e não apenas na memória interna do modelo. De forma resumida, o RAG é um mecanismo no qual o modelo primeiro busca informações relevantes em uma base de dados e depois usa esses dados como contexto para gerar a resposta.


Em síntese, o RAG é:

1. LLM + Recuperação de Informação
2. Base de conhecimento externa
3. Atualização em tempo real
4. Redução de alucinação

Agentes de IA (Agent AI): é um sistema de software orientado a objetivos que percebe informações do ambiente, toma decisões e executa ações de forma autônoma para alcançar um resultado definido. Diferentemente de um modelo de linguagem isolado, o agente combina raciocínio, memória, uso de ferramentas e, muitas vezes, planejamento, permitindo que ele atue de maneira contínua e adaptativa. Na prática, um agente de IA não apenas responde a comandos, mas avalia contextos, escolhe estratégias e interage com sistemas ou pessoas, aproximando-se de um comportamento inteligente operacional.

Em síntese, o Agente de IA possui:

- a) Objetivo explícito
- b) Planejamento e decisão
- c) Uso de ferramentas
- d) Memória de curto e longo prazo



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

e) Interação com ambiente

3. FRAMEWORK PARA CONSTRUÇÃO DE AGENTES DE IA

O agente de IA é modelado como um sistema cognitivo artificial orientado a objetivos, capaz de:

Perceber entradas multimodais

Raciocinar e planejar

Agir por meio de ferramentas

Aprender com memória e feedback

Interagir com humanos e outros agentes

Um **framework sistemático e reutilizável para construção de Agentes de IA**, alinhado ao estado da arte em IA Agencial, LLMs, RAG, uso de ferramentas, memória de longo prazo e arquiteturas multiagentes é apresentado nesta seção. O *framework* está estruturado em camadas e fases, de modo a facilitar tanto a implementação prática quanto a avaliação científica e industrial.


FASE 1 — DEFINIÇÃO DO PROPÓSITO DO AGENTE

Definir a tarefa do agente e o objetivo (*Goal*)

Objetivo: Estabelecer claramente o que o agente deve fazer e como o sucesso será medido.

Elementos-chave:

- Missão do agente (ex.: análise, decisão, recomendação, execução)
- Tipo de tarefa:
 - Reativa
 - Deliberativa
 - Autônoma
 - Colaborativa
- Métricas de sucesso – indicadores chave (*Key performance Indicators* – KPIs):
 - Precisão
 - Tempo de resposta



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- Robustez
- Confiabilidade

Output: Especificação formal do objetivo do agente (*Agent Goal Specification*)

FASE 2 — MODELAGEM DE ENTRADAS E SAÍDAS

Desenhar as entradas e saídas de forma estruturada

Objetivo: Reduzir ambiguidade e aumentar previsibilidade do comportamento do agente.

Entradas (Inputs):

- Texto estruturado (JSON, YAML)
- Dados sensoriais (voz, imagem, sensores IoT)
- Estado interno e histórico
- Contexto recuperado (RAG)

Saídas (Outputs):

- Texto natural (humano)
- Estruturas formais (JSON, XML, SQL)
- Ações executáveis (API calls, comandos)
- Sinais para outros agentes

Boas práticas:

- *Schemas* explícitos
- Validação sintática e semântica


FASE 3 — ENGENHARIA DE *PROMPTS* E PROTOCOLO DO AGENTE

Solicitar (*prompt*), ajustar e definir protocolo do agente

Objetivo: Definir o “contrato cognitivo” do agente.

Componentes do Prompt Base:

- Papel do agente (*Role*)
- Objetivo (*Goal*)
- Restrições (*Constraints*)
- Estilo de resposta
- Critérios de parada



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Protocolo do Agente:

- *Turn-taking*
- Regras de decisão
- Quando usar ferramentas
- Quando pedir ajuda humana

Output: *Agent Prompt Blueprint + Interaction Protocol*

FASE 4 — RACIOCÍNIO E USO DE FERRAMENTAS

Adicionar raciocínio e uso de ferramentas

Objetivo: Expandir capacidades além do texto.

Tipos de Raciocínio:

- Cadeia de pensamento (interno)
- Planejamento (*Plan* → *Act* → *Observe*)
- Verificação e autoavaliação

Ferramentas:

- APIs externas
- Bancos de dados
- Motores de busca
- Códigos e scripts
- Simuladores

Padrões comuns:

- ReAct
- Toolformer
- Planner–Executor


FASE 5 — ARQUITETURA MULTIAGENTE (SE NECESSÁRIO)

Estrutura lógica multiagente

Objetivo: Resolver problemas complexos por especialização e colaboração.

Tipos de agentes:

- Orquestrador (*Coordinator*)



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- Especialistas (*Experts*)
- Crítico/Auditor
- Executor

Topologias:

- Hierárquica
- Ponto a Ponto (*Peer-to-peer*)
- Blackboard
- Enxame (*Swarm*)

Comunicação:

- Protocolos estruturados
- Mensagens assinadas
- Memória compartilhada ou privada

FASE 6 — MEMÓRIA E CONTEXTO DE LONGO PRAZO

Adicionar memória e contexto de longo prazo

Objetivo: Tornar o agente adaptativo e cumulativo.

Tipos de Memória:

- Curto prazo (janela de contexto)
- Longo prazo:
 - Vetorial (*embeddings*)
 - Simbólica (regras, fatos)
 - Episódica (histórico de interações)


Técnicas:

- RAG
- Indexação semântica
- Esquecimento controlado

FASE 7 — MODALIDADES AVANÇADAS (OPCIONAL)

Adicionar recursos de voz ou visão

Objetivo: Expandir canais de percepção e interação.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Voz:

- Fala para Texto – ASR (*Speech-to-Text*)
- Texto para Fala (*Text-to-Speech*– TTS)
- Diálogo contínuo

Visão:

- Reconhecimento Ótico de Caracteres (*Optical Character Recognition* – OCR)
- Análise de imagens e vídeo
- Reconhecimento de padrões visuais

Integração: Multimodal → Representação unificada → Raciocínio

FASE 8 — FORMATO DE ENTREGA DOS RESULTADOS

Entregar o resultado em formato humano ou de máquina

Objetivo: Garantir interoperabilidade e usabilidade.

Formatos Humanos:

- Texto explicativo
- Relatórios *Dashboards*

Formatos de Máquina:

- JSON
- Protobuf
- Eventos
- Ações automatizadas


FASE 9 — INTERFACE COM O USUÁRIO

Criar uma interface de usuário

Objetivo: Facilitar controle, supervisão e confiança.

Interfaces possíveis:

- Chat
- Web app
- Mobile
- Voz



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- APIs

Recursos importantes:

- Transparência das decisões
- Logs e histórico
- Feedback humano (HITL)

FASE 10 — AVALIAÇÃO, MONITORAMENTO E GOVERNANÇA

Avaliar e monitorar o desempenho do agente

Objetivo: Garantir qualidade, segurança e melhoria contínua.


Métricas:

- Efetividade da tarefa
- Alucinação
- Uso de ferramentas
- Custo computacional

Monitoramento:

- Logs estruturados
- Avaliação automática
- *Feedback* humano
- Auditoria ética e regulatória

A Figura 2 apresenta um *pipeline* consolidado



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo




Figura 2: Pipeline de Criação de Agente de IA

A Figura 3 apresenta o *Framework* de forma resumida




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo



Figura 3: *Framework* para construção de Agentes de IA.

IA Agentica ou Agencial (AI *Agentic*): é o estágio mais recente de IA baseado em sistemas compostos por um ou mais agentes de IA autônomos, capazes de planejar, decidir, agir e colaborar para atingir objetivos complexos. Diferentemente de soluções reativas ou de um agente isolado, a IA agêntica integra modelos de linguagem, memória de longo prazo, uso de ferramentas, coordenação multiagente e mecanismos de



governança, permitindo adaptação contínua ao ambiente. Esse paradigma aproxima a IA de sistemas organizacionais inteligentes, nos quais diferentes agentes especializados cooperam, supervisionam e evoluem de forma estruturada.


Em síntese, a IA Agencial (Agêntica) contempla:

- Múltiplos agentes especializados
- Coordenação e orquestração
- Comunicação interagente
- Memória coletiva
- Governança e monitoramento

O quadro 1 apresenta um comparativo entre LLM, RAG, Agentes de IA e IA Agencial.

Quadro 1: Comparativo entre LLM, RAG, Agente de IA e IA Agencial


Dimensão	LLM	RAG	Agente de IA	IA Agencial / Agêntica
Definição	Modelo estatístico de linguagem treinado em grandes corpora	Arquitetura que combina recuperação de informação com LLM	Entidade de software orientada a objetivos que percebe, decide e age	Paradigma completo de sistemas autônomos baseados em agentes
Papel principal	Gerar e compreender linguagem	Gerar respostas com base em conhecimento externo	Executar tarefas de forma autônoma	Orquestrar ecossistemas de agentes inteligentes
Autonomia	Nenhuma (reativo)	Muito baixa	Média a alta	Alta a muito alta
Capacidade de decisão	Não decide	Limitada ao conteúdo recuperado	Decide ações e sequências	Decide, planeja, coordena e adapta
Uso de ferramentas	Não	Indiretamente	Sim (APIs, código, sistemas)	Sim, de forma distribuída e coordenada
Memória de longo prazo	Não	Sim (externa)	Sim (curto e longo prazo)	Sim (individual, coletiva e compartilhada)
Atualização do conhecimento	Somente via re-treino	Em tempo real	Em tempo real	Contínua e adaptativa
Raciocínio	Implícito e limitado	Assistido por contexto	Explícito (planejamento, reflexão)	Distribuído, colaborativo e hierárquico
Interação com ambiente	Nenhuma	Passiva	Ativa	Ativa e multiambiental
Estrutura interna	Rede neural Transformer	LLM + mecanismo de busca	LLM + memória + ferramentas + controle	Conjunto de agentes + protocolos + governança
Multiagentes	Não	Não	Opcional	Essencial
Escalabilidade funcional	Baixa	Média	Alta	Muito alta
Fraquezas	Limitado para Treinar, generalização dos dados, imprecisões	Depende de fontes externas, devem ser atuais para trabalhar de forma efetiva	Requer supervisão, são limitados em tarefas altamente complexas	Complexos e muito difíceis de configurar, requerem supervisão e controle
Forças	Simple de usar, bom para gerar texto criativamente	Pode operar como uma IA assistiva, com texto em tempo real	Tarefas Automatizadas, capacidade de aprendizado	Gerencia interconexões, as las resolvem problemas em camadas de forma inteligente
Confiabilidade	Moderada	Alta (se bem indexado)	Alta	Muito alta (com auditoria e redundância)
Exemplos	Chatbot simples, ChatGPT, Claude, Gemini, Bing	Chat corporativo com base documental, Perplexity AI, Bing, Search, You.com	Assistente autônomo que executa tarefas, Auto-GPT, Devin, TaskMatrix	Sistema corporativo de agentes especializados, Cognosy, MetaGPTT, CrewAI
Nível de abstração	Modelo	Arquitetura	Sistema	Paradigma



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Visão Evolutiva (Linha de Maturidade)



- LLM → linguagem
- RAG → linguagem + conhecimento
- Agente de IA → conhecimento + ação
- IA Agencial → ação + coordenação + adaptação sistêmica

Síntese conceitual

- LLM é o cérebro linguístico
- RAG é a memória factual externa
- Agente de IA é o ator autônomo
- IA Agencial é o sistema cognitivo coletivo

IA Agencial não é apenas um agente. Ela representa uma mudança de paradigma, aproximando a IA de:


- Sistemas complexos,
- Organizações artificiais,
- Inteligência distribuída,
- E arquiteturas cognitivas inspiradas em sociedades humanas.

4. EXEMPLOS DE APLICAÇÃO DE IA AGENCIAL

4.1 Exemplos Acadêmicos e Experimentais

4.1.1 *Generative Agents* (Stanford / Google)

- **Descrição:** Agentes baseados em LLMs com memória episódica, planejamento e reflexão.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- **Capacidades agênticas:**
 - Memória de longo prazo
 - Planejamento diário
 - Interações sociais entre agentes

Importância: Demonstra agentes com comportamento contínuo e coerente ao longo do tempo.

4.1.2 Voyager (Agente Autônomo em Minecraft)

- **Descrição:** Agente que explora um ambiente aberto sem objetivos fixos.
- **Capacidades agênticas:**
 - Planejamento
 - Aprendizado contínuo
- **Importância:** Exemplo de autonomia de longo prazo e aprendizado incremental.

4.1.3 AutoGPT / BabyAGI (Experimentos iniciais)


- **Descrição:** Agentes capazes de decompor objetivos em subtarefas.
- **Capacidades agênticas:**
 - Planejamento iterativo
 - Execução automática
 - Avaliação de resultados

Limitação: Pouca governança e controle.

4.2 Exemplos Corporativos e Industriais

4.2.1 Agentes Corporativos Autônomos

- **Exemplo:** Agente que gerencia processos administrativos.
- **Funções:**
 - Ler e-mails
 - Atualizar sistemas
 - Gerar relatórios
- **Características agênticas:**



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- Objetivos claros
- Uso de múltiplas ferramentas
- Tomada de decisão condicionada

4.2.2 Agentes DevOps / Engenharia de *Software*

Exemplo: Agentes que:

- Analisam código
- Executam testes
- Criam *pull requests*
- **Capacidades:**
 - Planejamento técnico
 - Execução automática
 - Cooperação entre agentes (ex.: revisor + executor)

4.3 Sistemas Multiagente (IA Agêntica Plena)


4.3.1 Equipe de Agentes Especializados

- **Exemplo típico:**
 - Agente Planejador
 - Agente Especialista
 - Agente Crítico/Auditor
 - Agente Executor

4.3.2 Agentes em Cadeias de Suprimentos

- **Descrição:** Cada agente representa uma função:
 - Estoque
 - Logística
 - Demanda
- **Resultado:** Decisões distribuídas e adaptativas em tempo real.

4.4 Exemplos em IoT, Robótica e Sistemas Ciberfísicos



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

4.4.1 Agentes em *Smart Cities*

- **Agentes para:**
 - Tráfego
 - Energia
 - Segurança
- **Características:**
 - Percepção contínua
 - Decisão local
 - Coordenação global

4.4.2 Robôs Autônomos Colaborativos

- **Exemplo:** Frotas de *drones* ou robôs industriais.
- **Capacidades:**
 - Comunicação interagente
 - Planejamento coletivo
 - Reconfiguração dinâmica


4.5 Exemplos em Educação e Ciência

4.5.1 Tutores Inteligentes Agênticos

- **Descrição:** Agentes que acompanham o aluno ao longo do tempo.
- **Capacidades:**
 - Memória do progresso
 - Adaptação pedagógica
 - Planejamento de atividades

4.5.2 Agentes Científicos

- **Exemplo:** Agentes que:
 - Revisam literatura
 - Geram hipóteses
 - Analisam dados experimentais



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Um sistema é considerado IA agêntica quando apresenta, de forma integrada:

- Autonomia orientada a objetivos
- Planejamento e tomada de decisão
- Uso ativo de ferramentas
- Memória persistente
- Coordenação entre agentes (quando aplicável)
- Interação contínua com o ambiente

5. CONCLUSÃO

A evolução da IA não substitui os paradigmas anteriores, mas os incorpora e expande, abrindo caminho para aplicações mais robustas, adaptativas e alinhadas a contextos complexos do mundo real. Porém, a maioria das pessoas ainda usa os termos LLM, RAG, Agente de IA e IA Agêntica de forma intercambiável, mas eles não são a mesma coisa. Se o pesquisador estiver construindo sistemas de IA generativa (*Generative AI* – GenAI) deve compreender a diferença entre LLM, RAG, Agente de IA e IA Agêntica, suas limitações e aplicações potenciais. A sociedade está migrando de modelos de resposta única para arquiteturas de IA autônomas, baseadas em raciocínio e conscientes de ferramentas. A IA Agêntica não é apenas uma IA que responde, mas uma IA que decide, age e coordena.

REFERÊNCIAS


BOMMASANI, Rishi. On the opportunities and risks of foundation models. arXiv preprint arXiv:2108.07258,2021.

BROWN, Tom et al. Language models are few-shot learners. Advances in neural information processing systems, v. 33, p. 1877-1901, 2020.

GOODFELLOW, Ian J. et al. Generative adversarial nets. Advances in neural information processing systems ,v. 27, 2014.

LEWIS, Patrick et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. Advances in neural information processing systems, v. 33, p. 9459-9474, 2020.

PARK, Joon Sung et al. Generative agents: Interactive simulacra of human behavior. arXiv. Org (2023, April 7)<https://arxiv.org/abs/2304.03442> v2, 2023.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

RUSSELL, S. J.; NORVIG, P. Artificial Intelligence: A Modern Approach, 4th, global edition Pearson. Harlow, UK, 2021.


SCHICK, Timo et al. Tool former: Language models can teach themselves to use tools. Advances in Neural Information Processing Systems, v. 36, p. 68539-68551, 2023.

VASWANI, Ashish et al. Attention is all you need. Advances in neural information processing systems, v. 30, 2017.

XI, Zhiheng et al. The rise and potential of large language model based agents: A survey. Science China Information Sciences, v. 68, n. 2, p. 121101, 2025.

YAO, Shunyu et al. React: Synergizing reasoning and acting in language models. In: The eleventh international conference on learning representations. 2022.

WOOLDRIDGE, Michael. An introduction to multiagent systems. John wiley & sons, 2009.



Post 15: Transformers: A Arquitetura Que Revolucionou a IA Contemporânea

1. INTRODUÇÃO

Na área de processamento de linguagem natural – PLN (*Natural Language Processing* - NLP), a grande ruptura no desenvolvimento da inteligência artificial (IA) ocorreu com a arquitetura de aprendizado profundo (*Deep Learning* - DL), chamada transformador (*Transformer*). Essa arquitetura foi proposta por pesquisadores do Google, até de forma modesta, em um artigo “*preprint*” de 2017, chamado “Attention is all you need!” [1].

As redes *Transformers* permitiram o surgimento dos Modelos de Linguagem de Grande Escala (*Large language Models* - LLMs), capazes de gerar textos coerentes, responder perguntas, resumir documentos e auxiliar na programação.

Os LLMs operam prevendo a próxima palavra mais provável em um contexto, o que explica tanto seu poder quanto suas limitações. Isso permitiu a construção de arquiteturas complexas de IA Generativa que se vê hoje, capaz de criar conteúdo (texto, códigos, áudios, vídeos, ...) e até atendentes autônomos orientados a objetivos, chamados IA Agencial ou Agêntica (*Agentic AI*) [2].

2. REDES TRANSFORMER: UMA EXPLICAÇÃO SIMPLES

As **redes Transformer** são uma arquitetura de redes neurais desenvolvida para lidar de forma eficiente com **dados sequenciais**, como textos, sinais e códigos. Eles introduzem uma mudança de paradigma ao eliminar a recorrência e utilizar **mecanismos de atenção**. Diferentemente de arquiteturas mais antigas, como redes neurais recorrentes (*Recurrent Neural Networks* - RNNs), os Transformers **processam todos os elementos da sequência em paralelo**, o que torna o treinamento mais rápido e escalável. Essa mudança explica o por que os Transformes se tornaram a espinha dorsal da IA Generativa contemporânea [3].

2.1. Principais blocos de uma rede Transformer

A Figura 1 apresenta a arquitetura de uma rede *Transformer* [1]. Ela é formada por blocos empilhados, que se repetem ao longo da arquitetura.





Figura 1 – Arquitetura do Transformer
Fonte: Adaptado de [1].

Os principais componentes são [4]:

- Camada de *Embedding*:** Cada palavra, símbolo ou unidade de entrada é convertida em um vetor numérico contínuo, chamado *embedding*, que representa seu significado de forma matemática.
- Codificação Posicional (*Positional Encoding*):** Como o *Transformer* não possui memória sequencial explícita, ele adiciona informações sobre a **posição dos *tokens*** na sequência, permitindo distinguir, por exemplo, o início e o fim de uma frase.
- Mecanismo de Atenção (*Self-Attention*):** Esse é o núcleo do *Transformer*. Ele permite que cada *token* “preste atenção” a outros *tokens* da sequência, atribuindo pesos diferentes conforme a relevância contextual. Assim, o modelo consegue capturar relações de longo alcance em um texto.



- d) **Atenção Multi-Cabeça (Multi-Head Attention):** Em vez de uma única atenção, o modelo utiliza várias atenções em paralelo, permitindo capturar diferentes tipos de relações semânticas e sintáticas ao mesmo tempo.
- e) **Redes Feedforward:** Após a atenção, cada **token** passa por uma pequena rede neural totalmente conectada, que transforma os vetores e aumenta a capacidade de representação do modelo.
- f) **Normalização e Conexões Residuais:** Esses mecanismos ajudam a estabilizar o treinamento e permitem que a informação flua melhor pelas camadas profundas da rede.
- g) **Saída Camada Densa Linear + Softmax:** A camada de rede neural densa linear possui o tamanho do vocabulário. Logo após, a função Softmax (ou função exponencial normalizada) é aplicada, gerando a distribuição de probabilidades de cada uma das palavras.


2.2 O que é um token para os Transformers?

Um **token** é a unidade básica de processamento usada pelos *Transformers*. Dependendo do modelo, um *token* pode representar uma palavra inteira, parte de uma palavra (subpalavra), um caractere ou até símbolos especiais [5].

Por exemplo, a palavra “aprendizado” pode ser dividida em vários *tokens* menores. O modelo não “entende” palavras diretamente, mas sim **sequências de tokens representadas por números**.

Esses tokens são então transformados em incorporações (**embeddings**) e processados pelo mecanismo de atenção, permitindo ao modelo aprender padrões linguísticos, semânticos e contextuais.

Nota: Embora os *Transformers* sejam extremamente eficazes em tarefas de linguagem e geração de conteúdo, eles **não possuem compreensão ou consciência**, operando exclusivamente por meio de **padrões estatísticos** aprendidos a partir de grandes **volumes de dados**.



Um tutorial de uso e exemplo de Rede *Transformer* em Python está disponível respectivamente nas referências [5] e [6]. Este exemplo pode ser executado diretamente via a plataforma Google Colab. Note o tempo que leva para executar o treinamento do Transformer neste exemplo.

3. CARACTERÍSTICAS DOS TRANSFORMERS


A Tabela 1 apresenta as características principais dos *Transformers*.

Tabela 1 – Características dos *Transformers*.

Dimensão	Descrição
Arquitetura	Baseada em atenção (Self-Attention), sem recorrência ou convolução
Processamento	Paralelo sobre toda a sequência de tokens
Unidade Básica	Token (palavra, subpalavra ou símbolo)
Blocos Principais	Embedding + Positional Encoding, Multi-Head Attention, Feed-Forward Networks, Normalização e Conexões residuais
Memória Contextual	Global — cada token pode atender a todos os outros
Escalabilidade	Alta, especialmente em GPUs/TPUs
Aplicações Típicas	LLMs, tradução, sumarização, chatbots, visão multimodal

4. TRANSFORMERS: USAR OU NÃO USAR?

Apesar de revolucionária, nem sempre os *Transformers* são a melhor tecnologia a ser aplicada. As Tabelas 2 e 3 apresentam respectivamente as vantagens e desvantagens desta tecnologia revolucionária.

**Tabela 2** – Vantagens de se usar os *Transformers*.


Vantagem	Impacto Prático
Captura eficiente de dependências longas	Melhor compreensão de contexto em textos extensos
Processamento altamente paralelizável	Treinamento mais rápido em grande escala
Excelente desempenho em PLN e IA Generativa	Base de modelos como GPT, BERT, T5, LLaMA
Arquitetura modular e flexível	Fácil adaptação para texto, imagem, áudio e código
Aprendizado contextual profundo	Maior qualidade em tarefas de geração e compreensão

Tabela 3 – Desvantagens de se usar os *Transformers*.

Desvantagem	Implicação
Custo computacional elevado	Exige infraestrutura robusta (GPU/TPU)
Complexidade quadrática da atenção	Limitações para sequências muito longas
Alto consumo de memória	Dificulta uso em dispositivos embarcados
Pouca interpretabilidade	Decisões difíceis de explicar (black box)
Dependência de grandes volumes de dados	Menor eficiência em cenários com poucos dados

4.1. Use *Transformers* quando...

- ✓ O problema envolve sequências complexas
 - Texto longo, documentos, código-fonte, séries multimodais.
 - Ex.: *chatbots*, análise jurídica, sumarização de relatórios, tradução automática.
- ✓ O contexto global é relevante
 - Relações entre elementos distantes da sequência são importantes.
 - Ex.: interpretação semântica, raciocínio contextual, PLN.
- ✓ Há disponibilidade de dados em grande escala
 - Grandes volumes de dados rotulados ou não rotulados.
 - Ex.: treinamento ou ajuste fino (*fine-tuning*) de LLMs.
- ✓ Existe infraestrutura computacional adequada
 - GPUs/TPUs, ambientes em nuvem ou *clusters*.
 - Ex.: empresas, universidades, centros de pesquisa.
- ✓ O objetivo envolve geração de conteúdo
 - Texto, imagem, código, áudio ou múltiplas modalidades.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- Ex.: IA Generativa, assistentes virtuais, recomendação contextual.


4.2. Evite os *Transformers* quando...

- ✖ O problema é simples ou bem estruturado
 - Relações diretas entre entrada e saída.
 - Ex.: regressão linear, classificação tabular simples.
- ✖ Os dados são escassos
 - Poucos exemplos disponíveis para treinamento.
 - Ex.: pequenos *datasets* industriais ou clínicos.
- ✖ Há restrições severas de recursos
 - Sistemas embarcados, computação de borda (*edge computing*), Internet das Coisas (*Internet of Things* - IoT).
 - Ex.: sensores, dispositivos móveis de baixo consumo.
- ✖ A interpretabilidade é requisito central
 - Ambientes regulados ou críticos.
 - Ex.: decisões médicas, jurídicas ou financeiras explicáveis.
- ✖ A latência precisa ser mínima
 - Respostas em tempo real com custo computacional reduzido.
 - Ex.: controle industrial em tempo real.

A Tabela 4 traz aplicações mais indicadas para os *Transformers* e outros modelos de IA [7][8][9].

Tabela 4 – Aplicações e Modelos de IA mais indicados.

Cenário	Modelo mais indicado
Texto, linguagem, multimodal	Transformers
Dados tabulares estruturados	Árvores, regressão, XGBoost
Séries temporais simples	RNNs simples, ARIMA
Edge computing	CNNs leves, modelos clássicos
Alta exigência de explicabilidade	Modelos simbólicos ou estatísticos




5. CONSIDERAÇÕES FINAIS

Os *Transformers* são de fato um ponto de virada de chave e o propulsor para a revolução da IA contemporânea. Os *Transformers* oferecem desempenho superior e escalabilidade, porém com o custo de maior complexidade computacional e desafios de interpretabilidade. Assim o uso do *Transformer* deve ser estrategicamente avaliado conforme o contexto, recursos disponíveis e objetivos a serem atingidos.

REFERÊNCIAS

- [1] VASWANI, Ashish et al. Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS'17, 6000–6010. Red Hook, NY, USA: Curran Associates Inc. ISBN 9781510860964.
- [2] CARVALHO JUNIOR, Arnaldo De. Evolução da IA Tradicional para a IA Generativa e Agencial. EAILab, Labmax, IFSP, 2026. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%2014%20-%20Evolução%20da%20IA%20Tradicional%20para%20Generativa%20e%20Agencial.pdf. Acesso em: Fevereiro 05, 2026.
- [3] DEEP LEARNING BOOK. Capítulo 85 – Transformadores – O Estado da Arte em Processamento de Linguagem Natural, Data Science Academy, 2025. Disponível em: <https://www.deeplearningbook.com.br/transformadores-o-estado-da-arte-em-processamento-de-linguagem-natural/>. Acesso em: Fevereiro 05, 2026.
- [4] DE PAIVA, Eduardo Soares; PEREIRA, Fernando Sola. Capítulo 2 - Deep learning para processamento de linguagem natural, Tópicos Especiais em Sistemas de Informação, Minicursos SBSI, Sociedade Brasileira da Computação, 2022. Disponível em: <https://books-sol.sbc.org.br/index.php/sbc/catalog/view/86/379/654>. Acesso em: Fevereiro 05, 2026.
- [5] CARVALHO JUNIOR, Arnaldo De. Arquitetura dos Transformadores. EIALab-IFSP, Repositório GitHub, 2025. Disponível em: https://github.com/EAILAB-IFSP/AI_ALGORITHMS/blob/AI_Algorithms/Arquitetura%20dos%20Transformadores.pdf. Acesso em: Fevereiro 05, 2026.
- [6] CARVALHO JUNIOR, Arnaldo De. Transformer Using Pytorch. EAILab-IFSP, 2025. Disponível em: <https://colab.research.google.com/drive/13IkORfUEtOwmMC4idP1g-CukSXlGqEds?usp=sharing>. Acesso em: Fevereiro 05, 2026.
- [7] CARVALHO JUNIOR, Arnaldo De. Principais Algoritmos Utilizados em Inteligência Artificial, EAILAB, IFSP, 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%208%20-%20Principais%20Algoritmos%20de%20IA.pdf. Acesso em: Maio 25, 2026.




EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

[8] CARVALHO JUNIOR, Arnaldo De. Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML. EAILAB, IFSP, 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%205%20-%20RNAs.pdf. Acesso em: Maio 25, 2026.

[9] CARVALHO JUNIOR, Arnaldo De. O Poder Das CNNs Em Aplicações de ML Envolvendo Identificação e Classificação de Imagens. EAILAB, IFSP, 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%209%20-%20O%20Poder%20das%20CNNs%20em%20ML.pdf. Acesso em: Maio 25, 2026.



Post 16: Probabilidade Aplicada à IA

1. INTRODUÇÃO


O objetivo deste *post* não é aprofundar na matemática de cada modelo de probabilidade utilizado em inteligência artificial (IA), mas entender quando eles fazem sentido e onde podem ser aplicados em problemas de negócio [1].

Em muitos problemas reais, não há respostas absolutas, apenas trabalha-se com chances, padrões, riscos e previsões [1].

2. MODELOS DE PROBABILIDADE UTILIZADOS EM IA

Modelos de probabilidade que ajudam sistemas de IA a transformar incerteza em decisões mais confiáveis [1]. Os nove modelos que utilizam ferramentas de probabilidade para fazer melhores previsões e tomada de decisões são:

- a) **Naive Bayes:** O Naive Bayes é um algoritmo de aprendizado de máquina (*machine learning* - ML) utilizado para classificação de dados, baseado no conceito matemático conhecido como Teorema de Bayes. Ele recebe o nome “*naive*” (ingênuo) porque assume que todas as características analisadas são independentes entre si, algo que nem sempre ocorre na prática. Mesmo com essa simplificação, o método costuma apresentar bons resultados em tarefas como filtragem de *spam*, análise de sentimentos e categorização de documentos. De forma simples, o *Naive Bayes* calcula a probabilidade de uma informação pertencer a determinada categoria com base em evidências observadas, escolhendo aquela que apresenta a maior probabilidade de ocorrência. Vide Figura 1a [2],[3].
- b) **Regressão Logística:** técnica estatística e de ML utilizada para prever a probabilidade de ocorrência de um evento que possui apenas dois resultados possíveis, como “sim” ou “não”, “aprovado” ou “reprovado”, “cliente compra” ou “cliente não compra”. Diferentemente da regressão linear, que estima valores numéricos, a regressão logística calcula a chance de determinado resultado acontecer com base em uma ou mais variáveis explicativas, permitindo apoiar decisões e classificações em diversas áreas, como saúde, marketing, finanças e



ciência de dados. Por exemplo, um banco pode utilizá-la para estimar a probabilidade de um cliente pagar ou não um empréstimo, considerando fatores como renda, idade e histórico financeiro. Vide Figura 1b [1],[4].

- c) **Árvore de Decisão (*Decision Tree*)**: Algoritmo de ML que organiza informações em uma estrutura semelhante a uma árvore, na qual cada ramo representa uma pergunta ou condição e cada folha representa uma decisão ou resultado final. Seu funcionamento é intuitivo, pois imita o processo de tomada de decisão humana por meio de perguntas sequenciais, como “a renda é maior que determinado valor?” ou “o cliente possui histórico de inadimplência?”. A partir dessas respostas, o algoritmo segue diferentes caminhos até chegar a uma classificação ou previsão. Por sua facilidade de interpretação e visualização, as árvores de decisão são amplamente utilizadas em áreas como finanças, saúde, marketing e análise de risco. Vide Figura 1c [1],[3].
- d) **Vizinhos k-Próximos (*k-Nearest Neighbors – kNN*)**: Algoritmo de ML que toma decisões com base na semelhança entre os dados. Seu funcionamento pode ser comparado à ideia de que “objetos parecidos tendem a pertencer ao mesmo grupo”. Quando um novo dado precisa ser classificado, o algoritmo procura os k exemplos mais próximos dele em um conjunto de dados já conhecido e verifica qual categoria aparece com maior frequência entre esses vizinhos. Por exemplo, para identificar se um e-mail é spam, o k-NN compara suas características com mensagens já classificadas e atribui a categoria predominante entre os exemplos mais semelhantes. Por sua simplicidade e eficiência em diversos problemas de classificação e previsão, o k-NN é amplamente utilizado em aplicações de mineração de dados e IA. Vide Figura 2a [1],[5].






Figura 1: Modelos Estatísticos utilizados em IA – Naive Bayes (a), Regressão Logística (b), Árvore de Decisão (*Decision Tree*) (c).

- e) **Floresta Aleatória (*Random Forest* - RF):** Algoritmo de ML que combina várias **árvores de decisão** para produzir resultados mais precisos e confiáveis. Em vez de depender de uma única árvore, o método cria diversas árvores utilizando diferentes amostras dos dados e, ao final, reúne as respostas de todas elas para tomar uma decisão, geralmente por votação. Essa estratégia reduz a influência de erros individuais e melhora a capacidade de generalização do modelo. De forma simples, é como consultar vários especialistas sobre um mesmo problema e considerar a opinião da maioria para chegar a uma conclusão mais segura. Por sua robustez e bom desempenho, o **Random Forest** é amplamente utilizado em áreas como finanças, saúde, marketing e detecção de fraudes. Vide Figura 2b [1],[6].
- f) **Aumento de Gradiente (*Gradient Boosting*):** Técnica de ML que combina várias **árvores de decisão simples** para criar um modelo mais preciso e eficiente. O método funciona de forma sequencial: cada nova árvore é treinada para corrigir os erros cometidos pelas árvores anteriores, melhorando gradualmente a qualidade das previsões. Essa abordagem é muito utilizada em problemas de classificação e regressão, sendo reconhecida por seu alto desempenho em tarefas como previsão



de vendas, análise de risco, detecção de fraudes e recomendação de produtos. Vide Figura 2c [1],[7].





Figura 2: Modelos Estatísticos utilizados em IA – Vizinhos k -próximos (*k-Nearest Neighbors* - kNN) (a), Floresta Aleatória (*Random Forest*) (b), Aumento de Gradiente (*Gradient Boosting*) (c).

- g) **Modelo de Mistura Gaussiana (Gaussian Mixture Model – GMM):** Técnica de ML usada para identificar grupos em um conjunto de dados. Diferentemente de métodos que atribuem cada elemento a um único grupo, o GMM considera que um dado pode pertencer a diferentes grupos com determinadas probabilidades. Ele assume que os dados são gerados por uma combinação de várias distribuições gaussianas (curvas em forma de sino), permitindo modelar conjuntos de dados mais complexos e com formatos variados. Essa técnica é amplamente utilizada em segmentação de clientes, reconhecimento de padrões, processamento de imagens e detecção de anomalias. Vide Figura 3a [1],[8].
- h) **Cadeias de Markov:** São modelos matemáticos usados em IA para prever eventos futuros com base apenas na situação atual, sem considerar todo o histórico anterior. Em termos simples, elas funcionam como um sistema de probabilidades que estima qual será o próximo passo a partir do estado presente. Essa abordagem é aplicada em diversas áreas da IA, como reconhecimento de fala, processamento de linguagem natural, sistemas de recomendação e análise de



comportamento, ajudando computadores a tomar decisões e fazer previsões em ambientes incertos. Vide Figura 3b [1],[9].

- i) **Modelo Oculto de Markov (*Hidden Markov Model* – HMM):** Técnica de IA utilizada para analisar sequências de eventos quando os estados reais do sistema não podem ser observados diretamente. Em vez disso, o modelo utiliza informações visíveis para inferir o que provavelmente está acontecendo “nos bastidores”. Uma analogia simples seria tentar descobrir o clima de um dia observando apenas as roupas que as pessoas usam. Os HMMs foram amplamente empregados em reconhecimento de fala, processamento de linguagem natural, bioinformática e sistemas de detecção de padrões, permitindo que computadores façam previsões e interpretações em situações de incerteza. Vide Figura 3c [1], [10].





Figura 3: Modelos Estatísticos utilizados em IA – Modelo de Mistura Gaussiana (*Gaussian Mixture Model* - GMM) (a), Cadeias de Markov (b), Modelo Oculto de Markov (*Hidden Markov Model* - HMM) (c).

CONCLUSÃO

A análise dos nove modelos de probabilidade apresentados neste *post* — Naive Bayes, Regressão Logística, Árvore de Decisão, k-NN, *Random Forest*, *Gradient Boosting*, GMM,



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

Cadeias de Markov e HMM — demonstra a diversidade de abordagens disponíveis para previsão e tomada de decisão em sistemas de IA.


Cada modelo apresenta características específicas que o tornam mais adequado para determinados tipos de problemas, desde tarefas de classificação e previsão até reconhecimento de padrões e análise de sequências temporais.

Enquanto métodos como *Naive Bayes* e Regressão Logística oferecem simplicidade, interpretabilidade e eficiência computacional, técnicas como *Random Forest* e *Gradient Boosting* proporcionam maior poder preditivo ao combinar múltiplos modelos. Por sua vez, o GMM destaca-se na identificação de agrupamentos probabilísticos em dados complexos, enquanto as Cadeias de Markov e os HMMs são especialmente úteis para modelar processos dinâmicos e eventos que evoluem ao longo do tempo.

Em conjunto, esses modelos evidenciam que não existe uma única solução ideal para todos os cenários de IA. A escolha do método mais adequado depende da natureza dos dados, dos objetivos da aplicação, dos requisitos de precisão e da necessidade de interpretação dos resultados. Dessa forma, o conhecimento das características, vantagens e limitações de cada abordagem é fundamental para o desenvolvimento de sistemas inteligentes mais robustos, confiáveis e capazes de apoiar a tomada de decisão baseada em evidências e probabilidades.

REFERÊNCIAS

- [1] BENEDICTO, Marcos De. 9 Modelos Que Utilizam Probabilidade Para Fazer Melhores Previsões e Tomada de Decisões, LinkedIn Post, 2026. Disponível em: https://media.licdn.com/dms/image/v2/D4D22AQEUUVUkIEu3Skw/feedshare-shrink_800/B4DZ6JdRUJI4BU-/0/1780422612539?e=1782950400&v=beta&t=4mEVYFj3ioMj_X2n0LWjq3Y0TOCzgSDNI96QkUIXvfk. Acesso em: Junho 10, 2026.
- [2] WIKIPEDIA CONTRIBUTORS, "Naive Bayes classifier," Wikipedia, The Free Encyclopedia, https://en.wikipedia.org/w/index.php?title=Naive_Bayes_classifier&oldid=1355160729, Acesso em: Junho 10, 2026.
- [3] FRANK, Eibe; HALL, Mark A. Data mining: practical machine learning tools and techniques. Morgan Kaufmann, 2011.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

- [4] JAMES, Gareth et al. An introduction to statistical learning: with applications in R. New York: springer, 2013.
- [5] TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. Introduction to data mining. Pearson Education India, 2016.
- [6] HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009.
- [7] FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. Annals of statistics, p. 1189-1232, 2001.
- [8] BISHOP, Christopher M.; NASRABADI, Nasser M. Pattern recognition and machine learning. New York: springer, 2006.
- [9] SUTTON, Richard S. et al. Reinforcement learning: An introduction. Cambridge: MIT press, 2nd edition, 2018. ISBN: 978-0-262-03924-6.
- [10] RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. Proceedings of the IEEE, v. 77, n. 2, p. 257-286, 1989. DOI:10.1109/5.18626.



EAILab

Laboratório de Inteligência Artificial Embarcada
Instituto Federal de São Paulo

ANEXO 1 - Pipeline de Classificação de Imagens com Inteligência Artificial

Projeto de iniciação científica (IC) desenvolvido pelo bacharelado em engenharia **Bruno Gobato Simões**, do IFSP campus Cubatão, intitulado *“Inteligência Artificial em computação de borda: Elaboração de um pipeline para classificação de imagens”*, em 2024, sob orientação do **Dr. Arnaldo de Carvalho Junior** e **Dr. Walter Augusto Varella** resultou na elaboração e publicação do **Pipeline de Classificação de Imagens com Inteligência Artificial**, na plataforma Github. A Figura 1 apresenta a tela principal do Pipeline.

Como criar uma Inteligência Artificial de Classificação de Imagens



Figura 1 – Página Principal do Pipeline de Classificação de Imagens com IA.
Fonte: O Autor (2024).

O Pipeline é totalmente interativo, podendo ser acessado através do QR-Code apresentado na a seguir, ou pelo link: <https://eailab-ifsp.github.io/AI-CLASSIFICATION-PIPELINE/>

